

线性代数基础

2026 年 8 月 18 日

本文主要的参考教材是 Gilbert Strang 所著的 *Introduction to Linear Algebra* (第五版)，这本书是线性代数最经典的教材之一，并且该书作者的线性代数网课 MIT 18.06 也是包括笔者在内的大部分人的线性代数启蒙课。本文不再把重点放在机械计算上，而是快速建立一套适合后续学习的线性代数语言。

1 坐标与向量

向量对我们其实并不陌生。中学里学过的平面直角坐标系，本质上就是在做一件事：用一对有次序的数 (x, y) 唯一确定平面上的一个点。例如点 $P(1, 2)$ 表示从原点出发，沿 x 轴方向走 1 个单位、再沿 y 轴方向走 2 个单位所到达的位置。如果从原点向 P 画一个箭头，这个有方向、有长度的箭头就是向量，记作 $\overrightarrow{OP}$ 。

到了三维空间，只是多出一个坐标：点 $(1, 2, 3)$ 对应从原点指向它的空间向量。更一般地， n 个有次序的数就对应 n 维空间中的一个点，也就对应一个从原点出发的 n 维向量。这正是线性代数中向量最直观的几何来源。

不过要留意书写习惯上的一个重要区别。中学里通常把坐标横着写成 $(1, 2, 3)$ ，这称为行向量；而在线性代数中，向量默认写成列向量，也就是竖着排列：

$$\boldsymbol{v} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \in \mathbb{R}^3. \quad (1.1)$$

这里的 $\mathbb{R}^3$ 表示所有三维实向量构成的集合。行向量与列向量只是同一个向量的两种写法，二者通过转置互相转换，转置用上标 T 表示：

$$\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}^T = (1, 2, 3), \quad (1, 2, 3)^T = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}. \quad (1.2)$$

为了节省版面，列向量在正文中也常横着写成 $\boldsymbol{v} = (1, 2, 3)^T$ 。

向量最基本的两种运算是向量加法与数乘。设

$$\boldsymbol{v} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}, \quad \boldsymbol{w} = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}, \quad (1.3)$$

则

$$\mathbf{v} + \mathbf{w} = \begin{bmatrix} v_1 + w_1 \\ v_2 + w_2 \end{bmatrix}, \quad c\mathbf{v} = \begin{bmatrix} cv_1 \\ cv_2 \end{bmatrix}. \quad (1.4)$$

把这两种运算合在一起，就得到线性代数中最重要的概念之一——线性组合：

$$c\mathbf{v} + d\mathbf{w}. \quad (1.5)$$

更一般地，若有 n 个向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ ，则

$$x_1\mathbf{v}_1 + x_2\mathbf{v}_2 + \dots + x_n\mathbf{v}_n \quad (1.6)$$

称为这些向量的一个线性组合，其中 $x_1, x_2, \dots, x_n$ 是标量系数。

这件事看似只是把向量乘上几个数再相加，但这里真正需要强调的是：不要只看某一个线性组合，而要看所有可能的线性组合。例如在三维空间中，一个非零向量 $\mathbf{u}$ 的所有倍数

$$c\mathbf{u}, \quad c \in \mathbb{R} \quad (1.7)$$

通常填满一条过原点的直线；

若 $\mathbf{u}$ 与 $\mathbf{v}$ 不共线，则

$$c\mathbf{u} + d\mathbf{v}, \quad c, d \in \mathbb{R} \quad (1.8)$$

会填满一个过原点的平面；




图 1：向量加法与线性组合的几何直观

再加入第三个不在该平面内的向量 $\mathbf{w}$ ，所有

$$c\mathbf{u} + d\mathbf{v} + e\mathbf{w}, \quad c, d, e \in \mathbb{R} \quad (1.9)$$

便会填满整个 $\mathbb{R}^3$ 。

如果第三个向量满足

$$\mathbf{w} = c\mathbf{u} + d\mathbf{v}, \quad (1.10)$$

也就是说 $\mathbf{w}$ 本来就落在 $\mathbf{u}$ 与 $\mathbf{v}$ 张成的平面内，那么三者的所有线性组合仍然只是原来那个平面，这时我们称 $\mathbf{u}, \mathbf{v}, \mathbf{w}$ 线性相关。要注意，线性相关并不是 $\mathbf{w}$ 一个向量的“问题”：只要系数 c, d 不为零，把上面的等式移项，就能得到

$$\mathbf{u} = \frac{1}{c}\mathbf{w} - \frac{d}{c}\mathbf{v}, \quad \mathbf{v} = \frac{1}{d}\mathbf{w} - \frac{c}{d}\mathbf{u}, \quad (1.11)$$

即 $\mathbf{u}$ 和 $\mathbf{v}$ 同样可以分别由另外两个向量表示出来。说到底，线性相关的本质是三个向量中至少有一个是“多余的”，它能由其余向量组合得到。

相反，如果 $\mathbf{w}$ 无法由 $\mathbf{u}$ 和 $\mathbf{v}$ 线性组合得到，那么 $\mathbf{u}$ 和 $\mathbf{v}$ 也同样无法由另外两个向量组合得到——否则把等式移项，就会推出 $\mathbf{w}$ 也能被组合出来，与假设矛盾。此时三个向量谁都不是多余的，我们称它们**线性无关**。

从这里可以先记住一个非常重要的判断方式：若存在不全为零的系数 $x_1, \dots, x_n$ ，使得判别方程

$$x_1 \mathbf{v}_1 + \dots + x_n \mathbf{v}_n = \mathbf{0}, \quad (1.12)$$

则这些向量线性相关；

对于该判别方程，如果只有

$$x_1 = x_2 = \dots = x_n = 0 \quad (1.13)$$

也就是它们的系数全部一起为 0 时，线性组合才能得到零向量，则这些向量线性无关。

2 长度、角度与点积运算

前一章介绍了向量以及向量的线性运算和组合。让我们回到单个向量本身，看向量的长度、角度以及点积运算。先看平面上的情形。直角三角形的两条直角边为 a 、 b 时，由勾股定理可知斜边长为 $\sqrt{a^2 + b^2}$ 。把平面向量 $\mathbf{v} = (3, 4)^\top$ 从原点画出来，它正好是一个直角三角形的斜边，两条直角边分别是 3 与 4，所以它的长度是

$$\sqrt{3^2 + 4^2} = \sqrt{25} = 5. \quad (2.1)$$

三维向量只多走一步。例如 $\mathbf{v} = (1, 2, 2)^\top$ ，先在前两个分量所在的水平面内用一次勾股定理，得到 $\sqrt{1^2 + 2^2} = \sqrt{5}$ ，再以它和第三个分量 2 为两条直角边用第二次：

$$\sqrt{(\sqrt{5})^2 + 2^2} = \sqrt{5 + 4} = \sqrt{9} = 3. \quad (2.2)$$

两次合起来，效果就是把三个分量各自平方、相加、再开方。照此推广， n 维向量 $\mathbf{v} = (v_1, v_2, \dots, v_n)^\top$ 的**长度**（也叫**范数**）定义为

$$\|\mathbf{v}\| = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2}. \quad (2.3)$$

长度总是非负的，并且只有零向量的长度为 0。把向量乘以数 c ，长度就乘以 c 的绝对值：

$$\|c\mathbf{v}\| = |c| \|\mathbf{v}\|. \quad (2.4)$$

长度为 1 的向量称为**单位向量**。只要 $\mathbf{v} \neq \mathbf{0}$ ，把它除以自己的长度，就得到与它同方向的单位向量：

$$\mathbf{u} = \frac{\mathbf{v}}{\|\mathbf{v}\|}. \quad (2.5)$$

例如 $\mathbf{v} = (3, 4)^\top$ 的长度是 5，于是

$$\mathbf{u} = \frac{\mathbf{v}}{\|\mathbf{v}\|} = \left(\frac{3}{5}, \frac{4}{5}\right)^\top, \quad \|\mathbf{u}\| = \sqrt{\left(\frac{3}{5}\right)^2 + \left(\frac{4}{5}\right)^2} = \sqrt{\frac{9+16}{25}} = 1. \quad (2.6)$$

有了长度，接下来的主角是两个向量之间的一种运算。先看一组具体的数： $\mathbf{v} = (1, 2, 3)^\top$ 与 $\mathbf{w} = (4, 5, 6)^\top$ 。把它们对应位置的分量两两相乘，再把三个乘积加起来：

$$1 \times 4 + 2 \times 5 + 3 \times 6 = 4 + 10 + 18 = 32. \quad (2.7)$$

这个“对应相乘再相加”的运算称为点积。一般地，两个 n 维向量 $\mathbf{v} = (v_1, v_2, \dots, v_n)^\top$ 与 $\mathbf{w} = (w_1, w_2, \dots, w_n)^\top$ 的点积定义为

$$\mathbf{v} \cdot \mathbf{w} = v_1 w_1 + v_2 w_2 + \dots + v_n w_n = \sum_{i=1}^n v_i w_i. \quad (2.8)$$

点积的结果是一个标量，而不是向量。点积与长度直接相关：向量与自身做点积，得到的正是长度的平方，

$$\mathbf{v} \cdot \mathbf{v} = v_1^2 + v_2^2 + \dots + v_n^2 = \|\mathbf{v}\|^2, \quad (2.9)$$

也就是说 $\|\mathbf{v}\| = \sqrt{\mathbf{v} \cdot \mathbf{v}}$ 。

点积真正的重要性在于，它还藏着两个向量之间的夹角。下面用余弦定理把这一点完整推出来。设 $\mathbf{v}$ 与 $\mathbf{w}$ 都是非零向量，夹角为 θ 。把它们从同一点画出，两个终点之间连线所对应的向量是 $\mathbf{v} - \mathbf{w}$ ，三者构成一个三角形。余弦定理给出

$$\|\mathbf{v} - \mathbf{w}\|^2 = \|\mathbf{v}\|^2 + \|\mathbf{w}\|^2 - 2\|\mathbf{v}\|\|\mathbf{w}\|\cos\theta. \quad (2.10)$$

等式左边可以用点积逐步展开。点积对加减法可以像普通乘法一样逐项展开，因为它本来就是按分量相乘再相加；展开过程是

$$\begin{aligned} \|\mathbf{v} - \mathbf{w}\|^2 &= (\mathbf{v} - \mathbf{w}) \cdot (\mathbf{v} - \mathbf{w}) \\ &= \mathbf{v} \cdot (\mathbf{v} - \mathbf{w}) - \mathbf{w} \cdot (\mathbf{v} - \mathbf{w}) \\ &= \mathbf{v} \cdot \mathbf{v} - \mathbf{v} \cdot \mathbf{w} - \mathbf{w} \cdot \mathbf{v} + \mathbf{w} \cdot \mathbf{w} \\ &= \|\mathbf{v}\|^2 - 2\mathbf{v} \cdot \mathbf{w} + \|\mathbf{w}\|^2, \end{aligned} \quad (2.11)$$

最后一步用到了 $\mathbf{v} \cdot \mathbf{v} = \|\mathbf{v}\|^2$ 与点积的交换律 $\mathbf{v} \cdot \mathbf{w} = \mathbf{w} \cdot \mathbf{v}$ （分量相乘的顺序不影响乘积），所以中间两项合在了一起。把这个结果与余弦定理对比，两边相同的 $\|\mathbf{v}\|^2 + \|\mathbf{w}\|^2$ 约去，剩下

$$-2\mathbf{v} \cdot \mathbf{w} = -2\|\mathbf{v}\|\|\mathbf{w}\|\cos\theta, \quad (2.12)$$

再约去 -2 ，得到点积的几何公式 (2.13)

$$\mathbf{v} \cdot \mathbf{w} = \|\mathbf{v}\|\|\mathbf{w}\|\cos\theta, \quad (2.13)$$

也就是夹角公式 (2.14)

$$\cos \theta = \frac{\mathbf{v} \cdot \mathbf{w}}{\|\mathbf{v}\| \|\mathbf{w}\|}. \quad (2.14)$$

回到刚才的数字例子，可以真正算出 $\mathbf{v} = (1, 2, 3)^\top$ 与 $\mathbf{w} = (4, 5, 6)^\top$ 的夹角。先算两个长度：

$$\|\mathbf{v}\| = \sqrt{1^2 + 2^2 + 3^2} = \sqrt{14}, \quad \|\mathbf{w}\| = \sqrt{4^2 + 5^2 + 6^2} = \sqrt{77}, \quad (2.15)$$

再代入夹角公式 (2.14)，点积已经在前面算出是 32：

$$\cos \theta = \frac{32}{\sqrt{14}\sqrt{77}} = \frac{32}{\sqrt{1078}} \approx 0.975, \quad \theta \approx 12.9^\circ. \quad (2.16)$$

由于长度总是非负的，点积的符号完全由 $\cos \theta$ 的符号决定：

- $\mathbf{v} \cdot \mathbf{w} > 0$ 当且仅当 $\cos \theta > 0$ ，此时夹角 θ 是锐角 ($0 \leq \theta < 90^\circ$)；
- $\mathbf{v} \cdot \mathbf{w} = 0$ 当且仅当 $\cos \theta = 0$ ，此时 $\theta = 90^\circ$ ；
- $\mathbf{v} \cdot \mathbf{w} < 0$ 当且仅当 $\cos \theta < 0$ ，此时夹角 θ 是钝角 ($90^\circ < \theta \leq 180^\circ$)。

第二种情形有一个专门的名字：当

$$\mathbf{v} \cdot \mathbf{w} = 0 \quad (2.17)$$

时，称 $\mathbf{v}$ 与 $\mathbf{w}$ **正交**，也就是互相垂直。零向量与任何向量的点积都是 0，所以它被视为与任何向量正交。正交还可以用本章开头的勾股定理来检验：由 $\|\mathbf{v} + \mathbf{w}\|^2 = \|\mathbf{v}\|^2 + 2\mathbf{v} \cdot \mathbf{w} + \|\mathbf{w}\|^2$ 可知， $\mathbf{v}$ 与 $\mathbf{w}$ 正交当且仅当

$$\|\mathbf{v} + \mathbf{w}\|^2 = \|\mathbf{v}\|^2 + \|\mathbf{w}\|^2, \quad (2.18)$$

这正是“直角三角形斜边的平方等于两直角边平方之和”的向量形式。正交是后面投影、最小二乘、正交基以及许多数值算法的基础。

夹角公式 (2.14) 还带来两条经常用到的长度估计。因为 $|\cos \theta| \leq 1$ ，对几何公式 (2.13) 两边取绝对值就得到

$$|\mathbf{v} \cdot \mathbf{w}| = \|\mathbf{v}\| \|\mathbf{w}\| |\cos \theta| \leq \|\mathbf{v}\| \|\mathbf{w}\|. \quad (2.19)$$

这称为 **Cauchy–Schwarz 不等式**：点积的绝对值不会超过两个向量长度的乘积。若 $\mathbf{v}$ 或 $\mathbf{w}$ 是零向量，不等式两边都是 0，自然成立；等号成立当且仅当 $|\cos \theta| = 1$ ，也就是两个向量共线。

由它还可以推出**三角不等式**。先把 $\|\mathbf{v} + \mathbf{w}\|^2$ 逐步展开：

$$\begin{aligned} \|\mathbf{v} + \mathbf{w}\|^2 &= (\mathbf{v} + \mathbf{w}) \cdot (\mathbf{v} + \mathbf{w}) \\ &= \mathbf{v} \cdot \mathbf{v} + \mathbf{v} \cdot \mathbf{w} + \mathbf{w} \cdot \mathbf{v} + \mathbf{w} \cdot \mathbf{w} \\ &= \|\mathbf{v}\|^2 + 2\mathbf{v} \cdot \mathbf{w} + \|\mathbf{w}\|^2. \end{aligned} \quad (2.20)$$

对中间点积用 Cauchy–Schwarz 不等式, $\mathbf{v} \cdot \mathbf{w} \leq |\mathbf{v} \cdot \mathbf{w}| \leq \|\mathbf{v}\| \|\mathbf{w}\|$, 于是

$$\|\mathbf{v} + \mathbf{w}\|^2 \leq \|\mathbf{v}\|^2 + 2\|\mathbf{v}\| \|\mathbf{w}\| + \|\mathbf{w}\|^2 = (\|\mathbf{v}\| + \|\mathbf{w}\|)^2. \quad (2.21)$$

两边都是非负实数, 开平方后得到

$$\|\mathbf{v} + \mathbf{w}\| \leq \|\mathbf{v}\| + \|\mathbf{w}\|. \quad (2.22)$$

几何上这正是三角形的基本事实: 任何一边的长度不超过另外两边长度之和。

3 矩阵

考虑一个简单的二元一次方程组:

$$x + 2y = 4, \quad 3x + 4y = 10, \quad (3.1)$$

未知数 x, y 其实只是占位的符号, 真正参与运算的是它们的系数和右端的数。把系数按原来的位置抄出来, 排成一张矩形数表:

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}. \quad (3.2)$$

这样的矩形数表就称为**矩阵**, 这里的矩阵是 2 行 2 列的, 我们也就称它为 2×2 矩阵。同理, 当它有 m 行 n 列时, 称为一个 $m \times n$ 矩阵。

方程增多、未知数增多时, 数表只是随之变大。例如在上面两个方程之后再添一个方程 $5x + 6y = 16$, 三个方程的系数排成的矩阵是

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}, \quad (3.3)$$

它有 3 行 2 列, 称为一个 3×2 矩阵。右端的三个数 4, 10, 16 也排成一列, 记作列向量 $\mathbf{b} = (4, 10, 16)^T$ 。

不过, 虽然这里的矩阵我们是看每一行的方程系数并塞进去, 矩阵也是一行一行组成的, 但如果从竖列的角度来看, 我们不难发现矩阵就是把许多列向量并排放在一起。把 A 按列拆开, 可以写为

$$A = [\mathbf{a}_1 \quad \mathbf{a}_2], \quad \mathbf{a}_1 = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix}. \quad (3.4)$$

这里我们可以很清晰的看出来, 矩阵 A 可以看作是 $\mathbf{a}_1$ 与 $\mathbf{a}_2$ 两个列向量组合排列起来而形成的。(help, 这里帮我将这个 $\mathbf{a}_1$ 与 $\mathbf{a}_2$ 格式规范一下, 进行加粗处理) 之

前我们讲过，线性组合是向量最重要的运算之一，矩阵我们可以认为是多个向量叠加在一起的，因此矩阵与向量之间的乘法也是符合线性组合的规则。设

$$\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad (3.5)$$

则矩阵与向量的乘积

$$A\boldsymbol{x} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (3.6)$$

规定为

$$\boxed{A\boldsymbol{x} = x_1\boldsymbol{a}_1 + x_2\boldsymbol{a}_2.} \quad (3.7)$$

也就是说， $A\boldsymbol{x}$ 的计算过程我们可以认为是矩阵 A 的列向量重新进行线性组合，而 $\boldsymbol{x}$ 的各个分量正是组合系数。这就是后文反复使用的列图像。

另一方面，也可以把 A 按行拆开。把 A 的行向量记作

$$\boldsymbol{r}_1^\top, \boldsymbol{r}_2^\top, \boldsymbol{r}_3^\top \quad (3.8)$$

其中 $\boldsymbol{r}_i^\top$ 表示第 i 行， $\boldsymbol{r}_i$ 是把这一行竖起来得到的列向量。点积 $\boldsymbol{v} \cdot \boldsymbol{w}$ 也可以写成 $\boldsymbol{v}^\top \boldsymbol{w}$ 的形式；用这个记号就有

$$A\boldsymbol{x} = \begin{bmatrix} \boldsymbol{r}_1^\top \boldsymbol{x} \\ \boldsymbol{r}_2^\top \boldsymbol{x} \\ \vdots \\ \boldsymbol{r}_m^\top \boldsymbol{x} \end{bmatrix}. \quad (3.9)$$

因此矩阵乘向量也可以理解为：每一行分别与输入向量做一次点积。

两种看法到底一不一样，取一个具体的 $\boldsymbol{x}$ 完整算一遍就知道了。取

$$\boldsymbol{x} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad (3.10)$$

即 $x_1 = 2$, $x_2 = 1$ 。先按列看：分别算出两列的倍数

$$2\boldsymbol{a}_1 = 2 \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} = \begin{bmatrix} 2 \\ 6 \\ 10 \end{bmatrix}, \quad 1\boldsymbol{a}_2 = \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix}, \quad (3.11)$$

再把它们相加。于是 $A\boldsymbol{x} = 2\boldsymbol{a}_1 + 1\boldsymbol{a}_2$ ，即

$$\begin{bmatrix} 2 \\ 6 \\ 10 \end{bmatrix} + \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix} = \begin{bmatrix} 2+2 \\ 6+4 \\ 10+6 \end{bmatrix} = \begin{bmatrix} 4 \\ 10 \\ 16 \end{bmatrix}. \quad (3.12)$$

再按行看。三行分别是 $\mathbf{r}_1^\top = (1, 2)$, $\mathbf{r}_2^\top = (3, 4)$, $\mathbf{r}_3^\top = (5, 6)$, 逐行与 $\mathbf{x}$ 做点积。第一行:

$$\mathbf{r}_1^\top \mathbf{x} = 1 \cdot 2 + 2 \cdot 1 = 4. \quad (3.13)$$

第二行:

$$\mathbf{r}_2^\top \mathbf{x} = 3 \cdot 2 + 4 \cdot 1 = 10. \quad (3.14)$$

第三行:

$$\mathbf{r}_3^\top \mathbf{x} = 5 \cdot 2 + 6 \cdot 1 = 16. \quad (3.15)$$

三个分量依次是 4, 10, 16, 拼起来正是

$$A\mathbf{x} = \begin{bmatrix} 4 \\ 10 \\ 16 \end{bmatrix}, \quad (3.16)$$

与按列看的结果完全相同。

这不是巧合, 逐分量对照一下就清楚了。按列看时, 组合 $x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2$ 的第 i 个分量, 是各列的第 i 个分量分别乘上系数再相加, 即 $x_1 a_{i1} + x_2 a_{i2}$; 按行看时, 第 i 行 (a_{i1}, a_{i2}) 与 $\mathbf{x}$ 的点积是 $a_{i1}x_1 + a_{i2}x_2$ 。两者是同一批乘法和加法, 只是分组顺序不同, 所以必然相等。比如第一个分量, 按列看是 $2 \cdot 1 + 1 \cdot 2 = 4$, 按行看是 $1 \cdot 2 + 2 \cdot 1 = 4$, 连中间步骤都对得上。

于是同一个 $A\mathbf{x}$ 有两种完全等价但关注点不同的理解:

1. 按列看: $A\mathbf{x}$ 是各列的线性组合;
2. 按行看: $A\mathbf{x}$ 的每个分量是某一行与 $\mathbf{x}$ 的点积。

只做数值计算时, “行乘列” 已经足够; 但要理解线性代数的结构, “列的线性组合” 往往更重要。

3.1 从 $A\mathbf{x}$ 到 $A\mathbf{x} = \mathbf{b}$

若 $\mathbf{x}$ 已知, 那么 $A\mathbf{x}$ 只是一次顺向计算, 就像刚才取 $\mathbf{x} = (2, 1)^\top$ 算出 $(4, 10, 16)^\top$ 那样。线性代数真正关心的经典问题通常反过来: 给定 A 和 $\mathbf{b}$, 寻找

$$A\mathbf{x} = \mathbf{b} \quad (3.17)$$

的解 $\mathbf{x}$ 。

从列向量的角度看, 这个问题等价于: 能否找到一组系数, 使 A 的列向量线性组合后恰好得到 $\mathbf{b}$? 继续用上面那组数来试: 给定同样的 A 和 $\mathbf{b} = (4, 10, 16)^\top$, 要找 x_1, x_2 使得

$$x_1 \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} + x_2 \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix} = \begin{bmatrix} 4 \\ 10 \\ 16 \end{bmatrix}. \quad (3.18)$$

按分量写出来，就是三个方程

$$x_1 + 2x_2 = 4, \quad 3x_1 + 4x_2 = 10, \quad 5x_1 + 6x_2 = 16. \quad (3.19)$$

用通常的消元方法处理前两个方程：第二式减去第一式的 3 倍，得 $-2x_2 = -2$ ，所以 $x_2 = 1$ ；代回第一式，得 $x_1 = 2$ 。解必须同时满足全部三个方程，因此还要代入第三个方程检验： $5 \cdot 2 + 6 \cdot 1 = 16$ ，恰好成立。所以 $\mathbf{x} = (2, 1)^\top$ 确实是解——它就是上一节按列组合时用过的那组系数。

一般地，若

$$A = \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{bmatrix}, \quad (3.20)$$

那么

$$A\mathbf{x} = \mathbf{b} \iff x_1\mathbf{a}_1 + \cdots + x_n\mathbf{a}_n = \mathbf{b}. \quad (3.21)$$

因此，求解线性方程组和寻找线性组合，本质上是同一件事。

对于可逆方阵 A ，解可以形式地写成

$$\mathbf{x} = A^{-1}\mathbf{b}. \quad (3.22)$$

这里的 A^{-1} 称为 A 的**逆矩阵**，暂时只需把它理解成“从输出 $\mathbf{b}$ 恢复输入 $\mathbf{x}$ 的逆变换”；实际求解大型方程组时并不会先显式算出 A^{-1} ，这一点留到消元与分解时再谈。

3.2 从 $A\mathbf{x} = \mathbf{0}$ 看线性相关

矩阵语言还能把第 1 章的线性相关问题写得非常紧凑。第 1 章的判别方程问的是：是否存在不全为零的系数，使线性组合等于零向量。若

$$A = \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_n \end{bmatrix}, \quad (3.23)$$

则

$$A\mathbf{x} = \mathbf{0} \quad (3.24)$$

等价于

$$x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \cdots + x_n\mathbf{a}_n = \mathbf{0}. \quad (3.25)$$

因此：

- 如果 $A\mathbf{x} = \mathbf{0}$ 只有零解 $\mathbf{x} = \mathbf{0}$ ，那么这些列向量线性无关；
- 如果存在非零解 $\mathbf{x} \neq \mathbf{0}$ ，那么这些列向量线性相关。

两种情况各算一个例子。先取只有两列的 A ，问 $A\mathbf{x} = \mathbf{0}$ 即

$$x_1 \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} + x_2 \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \quad (3.26)$$

有没有非零解。按分量写出来：

$$x_1 + 2x_2 = 0, \quad 3x_1 + 4x_2 = 0, \quad 5x_1 + 6x_2 = 0. \quad (3.27)$$

第二式减去第一式的 3 倍，得 $-2x_2 = 0$ ，即 $x_2 = 0$ ；代回第一式得 $x_1 = 0$ 。方程组只有零解 $\mathbf{x} = \mathbf{0}$ ，所以这两列线性无关。

再添上第三列 $\mathbf{a}_3 = (3, 7, 11)^\top$ 。先看一个事实：

$$\mathbf{a}_1 + \mathbf{a}_2 = \begin{bmatrix} 1+2 \\ 3+4 \\ 5+6 \end{bmatrix} = \begin{bmatrix} 3 \\ 7 \\ 11 \end{bmatrix} = \mathbf{a}_3, \quad (3.28)$$

即 $\mathbf{a}_3$ 能由前两列组合得到。移项可得 $\mathbf{a}_1 + \mathbf{a}_2 - \mathbf{a}_3 = \mathbf{0}$ ，也就是说 $\mathbf{x} = (1, 1, -1)^\top$ 满足

$$\begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} + \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix} - \begin{bmatrix} 3 \\ 7 \\ 11 \end{bmatrix} = \begin{bmatrix} 1+2-3 \\ 3+4-7 \\ 5+6-11 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}. \quad (3.29)$$

组合系数 $1, 1, -1$ 不全为零，所以 $\mathbf{x} = (1, 1, -1)^\top$ 是一个非零解，这三列线性相关。这正是第 1 章说的“第三个向量落在前两个向量张成的平面内，是多余的”。

对于方阵，这还会和矩阵是否可逆直接联系起来：列向量线性无关时， $A\mathbf{x} = \mathbf{0}$ 只有零解；列向量线性相关时就会出现非零解，矩阵不再可逆。这个联系后面还会被系统地展开。

4 线性方程、消元与矩阵分解

第 3 章已经把方程

$$A\mathbf{x} = \mathbf{b} \quad (4.1)$$

理解为“用 A 的列向量线性组合出 $\mathbf{b}$ ，组合系数就是 $\mathbf{x}$ ”。但当时只回答了“解是什么”，还没有回答“怎样算”。这一章就动手解决两个更进一步的问题：怎样一步一步把 $\mathbf{x}$ 求出来，以及求解过程反过来能告诉我们矩阵 A 的哪些结构。核心工具只有一个——高斯消元；而它走完全程之后，会自然长成矩阵分解。

4.1 行图像、列图像与高斯消元

从一个具体的方程组开始。取

$$A = \begin{bmatrix} 1 & -2 \\ 3 & 2 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x \\ y \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 11 \end{bmatrix}, \quad (4.2)$$

则 $A\mathbf{x} = \mathbf{b}$ 就是

$$\begin{cases} x - 2y = 1, \\ 3x + 2y = 11. \end{cases} \quad (4.3)$$

同一个方程组有两种看法。按行看，每个方程在平面上给出一条直线，两条直线的交点就是解；按列看，是在为 A 的两列寻找组合系数：

$$x \begin{bmatrix} 1 \\ 3 \end{bmatrix} + y \begin{bmatrix} -2 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 11 \end{bmatrix}. \quad (4.4)$$

二维时行图像很直观；进入高维以后，列向量的线性组合往往更加直接。但两种看法找到的必须是同一组 x, y 。

求解这样的方程组，最基本的方法是**高斯消元**：通过行与行之间的加减，把方程组逐步变成上三角形状，再从下往上把未知量逐个解出来。先用上面的例子把全过程走一遍。

第一步是消元：用第一个方程消去第二个方程里的 x 。第一个方程中 x 的系数 1 称为第一个**主元** (pivot)，它是这一步消元的基准，必须非零才能用。第二个方程中 x 的系数是 3，所以用第二个方程减去第一个方程的 3 倍：

$$(3x + 2y) - 3(x - 2y) = 11 - 3 \times 1. \quad (4.5)$$

左边展开： $3x$ 与 $-3x$ 抵消， $2y - 3 \times (-2y) = 2y + 6y = 8y$ ；右边是 $11 - 3 = 8$ 。方程组变成

$$\begin{cases} x - 2y = 1, \\ 8y = 8. \end{cases} \quad (4.6)$$

第一个方程原封不动，第二个方程里的 x 被消掉了。此时系数矩阵是

$$U = \begin{bmatrix} 1 & -2 \\ 0 & 8 \end{bmatrix}, \quad (4.7)$$

主对角线以下全是零，这样的矩阵称为**上三角矩阵**。两个主元 1 和 8 就站在对角线上。

第二步是**回代**：从最后一个方程开始，逐行向上求解。由 $8y = 8$ 得 $y = 1$ ；代回第一个方程，

$$x = 1 + 2y = 1 + 2 \times 1 = 3. \quad (4.8)$$

检验一下： $3 - 2 \times 1 = 1$ ， $3 \times 3 + 2 \times 1 = 11$ ，两个方程都满足。解就是 $(x, y) = (3, 1)$ 。

把这套动作写成一般公式 (4.9)。设第一个主元 $a_{11} \neq 0$ ，要消去第 i 行中的 a_{i1} ，先算**乘子**

$$\ell_{i1} = \frac{a_{i1}}{a_{11}}, \quad (4.9)$$

即“要消掉的元素”除以主元，然后做行变换

$$\text{第 } i \text{ 行} \leftarrow \text{第 } i \text{ 行} - \ell_{i1} \text{ 第 } 1 \text{ 行}. \quad (4.10)$$

上面的例子正是 $\ell_{21} = \frac{3}{1} = 3$ 。第一列处理完后，在主元右下方剩下的子矩阵里重复同样的事：找第二个主元，消去它下方的元素，再找第三个主元，直到方程组变成

$$U\mathbf{x} = \mathbf{c}, \quad (4.11)$$

其中 $\mathbf{c}$ 是 $\mathbf{b}$ 跟着做完同样行变换后的结果。最后回代，从最后一个未知量一路解回第一个。

主元必须非零，因为它要做除数。若某一步主元位置上是 0，而它下方还有非零元素，就交换两行，把非零元素换到主元位置上。若整列在当前主元位置及其以下全是零，这一列就无法产生新的主元，方程组会出现可以任意取值的未知量（自由变量），矩阵的秩也会小于列数。主元究竟出现在哪里、出现几个，后面关于秩和子空间的讨论会系统地回答。

4.2 消元矩阵与置换矩阵

每一次行消元都可以写成一次矩阵乘法。若要用第 j 行消去第 i 行中的元素，记对应的消元矩阵为 E_{ij} ：把单位矩阵 I 的 (i, j) 位置换成乘子的相反数 $-\ell_{ij}$ ，其余不动，则

$$E_{ij}A \quad (4.12)$$

就是完成该行变换后的矩阵。

还用上面的例子。“第二行减去 3 倍第一行”对应

$$E_{21} = \begin{bmatrix} 1 & 0 \\ -3 & 1 \end{bmatrix}. \quad (4.13)$$

真的把它乘到 A 上看：

$$E_{21}A = \begin{bmatrix} 1 & 0 \\ -3 & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 \\ 3 & 2 \end{bmatrix} = \begin{bmatrix} 1 & -2 \\ 0 & 8 \end{bmatrix} = U. \quad (4.14)$$

逐个元素核对：第一行是 1 倍原第一行加 0 倍原第二行，原封不动；第二行第一列是 $-3 \times 1 + 1 \times 3 = 0$ ，正是要消掉的位置；第二行第二列是 $-3 \times (-2) + 1 \times 2 = 8$ ，正是新主元。矩阵乘法忠实地执行了手算的那一步消元。

方程右端必须做完全相同的行变换：

$$E_{21}\mathbf{b} = \begin{bmatrix} 1 & 0 \\ -3 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 11 \end{bmatrix} = \begin{bmatrix} 1 \\ 8 \end{bmatrix} = \mathbf{c}. \quad (4.15)$$

于是 $E_{21}A\mathbf{x} = E_{21}\mathbf{b}$ 正好就是上三角系统 $U\mathbf{x} = \mathbf{c}$ 。为了不让同样的变换做两遍，实际消元时把 $\mathbf{b}$ 作为附加的一列接在 A 右边，拼成增广矩阵

$$[A \mid \mathbf{b}], \quad (4.16)$$

对整块一起做行变换。若消元需要多步，就有多个消元矩阵依次左乘：

$$E_k \cdots E_2 E_1 A = U, \quad E_k \cdots E_2 E_1 \mathbf{b} = \mathbf{c}. \quad (4.17)$$

注意书写顺序：先执行的那一步离 A 最近。

交换两行也有对应的矩阵。把单位矩阵 I 的第 i, j 两行互换，得到的矩阵称为**置换矩阵**；左乘它，就会交换矩阵的第 i, j 两行。二维的例子：

$$P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad P \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} y \\ x \end{bmatrix}, \quad (4.18)$$

两个分量真的被交换了。置换矩阵满足

$$P^{-1} = P^T. \quad (4.19)$$

原因是：把同一次交换再做一遍就回到了原来的排列，所以这个例子里 $PP = I$ ， P 是它自己的逆；而 P 本身又是对称的， $P^T = P$ ，合起来就是 $P^{-1} = P^T$ 。

4.3 矩阵乘法的结构

消元矩阵已经用到了矩阵乘法，现在把它本身的结构看清楚。设 $A \in \mathbb{R}^{m \times n}$ ， $B \in \mathbb{R}^{n \times p}$ ，则乘积 AB 有定义，并且

$$AB \in \mathbb{R}^{m \times p}. \quad (4.20)$$

内侧的两个 n 必须相同，结果的形状取外侧的 m 与 p 。

最熟悉的定义是“行乘列”：

$$(AB)_{ij} = \sum_{k=1}^n a_{ik} b_{kj}, \quad (4.21)$$

即 AB 的第 (i, j) 个元素，是 A 的第 i 行与 B 的第 j 列的点积。取一对具体的矩阵算到底：

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad B = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}. \quad (4.22)$$

四个元素分别是

$$\begin{aligned} (AB)_{11} &= 1 \times 5 + 2 \times 7 = 19, & (AB)_{12} &= 1 \times 6 + 2 \times 8 = 22, \\ (AB)_{21} &= 3 \times 5 + 4 \times 7 = 43, & (AB)_{22} &= 3 \times 6 + 4 \times 8 = 50, \end{aligned} \quad (4.23)$$

所以

$$AB = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}. \quad (4.24)$$

行乘列是算法，理解结构还要看列。若

$$B = \begin{bmatrix} \mathbf{b}_1 & \mathbf{b}_2 & \cdots & \mathbf{b}_p \end{bmatrix}, \quad (4.25)$$

则

$$AB = \begin{bmatrix} A\mathbf{b}_1 & A\mathbf{b}_2 & \cdots & A\mathbf{b}_p \end{bmatrix}. \quad (4.26)$$

A 逐列作用在 B 上，乘积的每一列都是 A 的列向量的线性组合——第 3 章的列图像在这里原样适用。反过来，也可以把 AB 的第 i 行看成 A 的第 i 行乘上整个 B 。

还有第三种看法。把 A 按列拆开、 B 按行拆开：

$$A = [\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_n], \quad B = \begin{bmatrix} \mathbf{r}_1^\top \\ \vdots \\ \mathbf{r}_n^\top \end{bmatrix}, \quad (4.27)$$

则

$$AB = \mathbf{a}_1 \mathbf{r}_1^\top + \mathbf{a}_2 \mathbf{r}_2^\top + \cdots + \mathbf{a}_n \mathbf{r}_n^\top. \quad (4.28)$$

每一项都是“列向量乘行向量”，结果是一个**秩一矩阵**：它的各列都是 $\mathbf{a}_i$ 的倍数，互相平行。用上面那对矩阵验证一下：

$$\begin{bmatrix} 1 \\ 3 \end{bmatrix} (5, 6) + \begin{bmatrix} 2 \\ 4 \end{bmatrix} (7, 8) = \begin{bmatrix} 5 & 6 \\ 15 & 18 \end{bmatrix} + \begin{bmatrix} 14 & 16 \\ 28 & 32 \end{bmatrix} = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}, \quad (4.29)$$

与行乘列的结果完全相同。这个写法在矩阵分解中还会反复出现。

运算律方面，矩阵乘法满足结合律

$$(AB)C = A(BC), \quad (4.30)$$

以及对加法的分配律，但一般不满足交换律：

$$AB \neq BA. \quad (4.31)$$

还用上面那对矩阵：

$$BA = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 23 & 34 \\ 31 & 46 \end{bmatrix} \neq AB. \quad (4.32)$$

甚至有时 AB 有定义而 BA 的维数根本对不上。所以矩阵乘积中因子的顺序不能随意调换，这也是上一节里消元矩阵必须按顺序书写的原因。

4.4 逆矩阵与 Gauss–Jordan 消元

对于方阵 A ，若存在矩阵 A^{-1} 使

$$A^{-1}A = AA^{-1} = I, \quad (4.33)$$

则称 A 可逆， A^{-1} 称为它的逆矩阵。此时

$$A\mathbf{x} = \mathbf{b} \quad (4.34)$$

有唯一解

$$\mathbf{x} = A^{-1}\mathbf{b}. \quad (4.35)$$

不过公式 (4.35) 的作用主要是说明结构；实际计算中通常不会先把逆矩阵算出来再乘 $\mathbf{b}$ 。第 3 章答应过解释原因，答案就是前面的消元：对具体的 $\mathbf{b}$ 直接消元，比求出整个 A^{-1} 再相乘省事得多。

判断可逆性最直接的工具是齐次方程。若存在非零向量 $\mathbf{x} \neq \mathbf{0}$ 满足

$$A\mathbf{x} = \mathbf{0}, \quad (4.36)$$

那么 A 不可能可逆——否则两边左乘 A^{-1} ，会推出 $\mathbf{x} = A^{-1}\mathbf{0} = \mathbf{0}$ ，矛盾。联系第 3 章的结论： $A\mathbf{x} = \mathbf{0}$ 有非零解，正是列向量线性相关。因此对方阵来说，下面三件事是同一件事： A 可逆；齐次方程只有零解； A 的列向量线性无关。

看一个不可逆的例子：

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}, \quad (4.37)$$

第二列是第一列的 2 倍，列向量线性相关。取 $\mathbf{x} = (2, -1)^T$ ：

$$A\mathbf{x} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 2-2 \\ 4-4 \end{bmatrix} = \mathbf{0}. \quad (4.38)$$

齐次方程有了非零解，这个 A 没有逆矩阵。

若确实需要把 A^{-1} 算出来，可以使用 **Gauss-Jordan 消元**：把 A 与单位矩阵拼接成

$$[A \mid I], \quad (4.39)$$

然后对整个增广矩阵做行变换，把左半边化成单位矩阵；此时右半边自动变成 A^{-1} ：

$$[A \mid I] \longrightarrow [I \mid A^{-1}]. \quad (4.40)$$

道理是：把所有行变换合并成一个矩阵 M ，左半边变成 I 说明 $MA = I$ ，即 $M = A^{-1}$ ；而同样的变换作用在右半边，得到的正是 $MI = M = A^{-1}$ 。

还用本章开头那个矩阵，把三步完整算完。从

$$\left[\begin{array}{cc|cc} 1 & -2 & 1 & 0 \\ 3 & 2 & 0 & 1 \end{array} \right] \quad (4.41)$$

出发。第一步，第二行减去 3 倍第一行：

$$\left[\begin{array}{cc|cc} 1 & -2 & 1 & 0 \\ 0 & 8 & -3 & 1 \end{array} \right]. \quad (4.42)$$

第二步，第二行除以 8，把主元化成 1：

$$\left[\begin{array}{cc|cc} 1 & -2 & 1 & 0 \\ 0 & 1 & -\frac{3}{8} & \frac{1}{8} \end{array} \right]. \quad (4.43)$$

第三步，第一行加上 2 倍第二行，把主元上方的 -2 也消掉：

$$\left[\begin{array}{cc|cc} 1 & 0 & \frac{1}{4} & \frac{1}{4} \\ 0 & 1 & -\frac{3}{8} & \frac{1}{8} \end{array} \right]. \quad (4.44)$$

左半边已经是 I ，右半边就是逆矩阵：

$$A^{-1} = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} \\ -\frac{3}{8} & \frac{1}{8} \end{bmatrix}. \quad (4.45)$$

验证一下： AA^{-1} 的 $(1,1)$ 元素是 $1 \times \frac{1}{4} + (-2) \times \left(-\frac{3}{8}\right) = \frac{1}{4} + \frac{3}{4} = 1$ ， $(2,1)$ 元素是 $3 \times \frac{1}{4} + 2 \times \left(-\frac{3}{8}\right) = 0$ ，确实得到了单位矩阵。

最后记住乘积的逆：

$$(AB)^{-1} = B^{-1}A^{-1}, \quad (4.46)$$

顺序必须反过来。直观地想：早上先穿袜子再穿鞋，晚上就得先脱鞋再脱袜子——连续两个操作的逆，要按相反的顺序执行。代数上直接验证：

$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AIA^{-1} = AA^{-1} = I. \quad (4.47)$$

矩阵乘法不能交换顺序，若随手写成 $A^{-1}B^{-1}$ ，乘开时中间的因子就约不掉了。

4.5 转置、对称矩阵与置换

矩阵转置把行和列互换：

$$(A^T)_{ij} = A_{ji}. \quad (4.48)$$

最常用的规则是

$$(A+B)^T = A^T + B^T, \quad (4.49)$$

$$(AB)^T = B^T A^T, \quad (4.50)$$

以及

$$(A^{-1})^T = (A^T)^{-1}. \quad (4.51)$$

乘积转置时顺序也会反过来，这一点和逆矩阵乘积的规则如出一辙，背后的道理相同：两个操作连做，拆开时次序倒置。用在矩阵乘法那一节算过的同一对矩阵验证第二条：

$$B^T A^T = \begin{bmatrix} 5 & 7 \\ 6 & 8 \end{bmatrix} \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix} = \begin{bmatrix} 19 & 43 \\ 22 & 50 \end{bmatrix} = (AB)^T. \quad (4.52)$$

若顺序不调换，直接算 $A^T B^T$ 得到的不是这个结果。

若

$$A^T = A, \quad (4.53)$$

即矩阵关于主对角线镜像对称, 则称 A 为**对称矩阵**。对称矩阵在后面的特征值问题中具有极其特殊的结构。至于置换矩阵, 前面已经看到同一次交换做两遍就还原, 即

$$P^T = P^{-1}. \quad (4.54)$$

因此置换矩阵同时也是后面会定义的正交矩阵。

4.6 LU 、 LDU 与 $PA = LU$

高斯消元不只是解方程的手法, 走完全程还会自然产生矩阵分解。还用同一个 2×2 例子推到底。前面已经算出

$$E_{21}A = U, \quad E_{21} = \begin{bmatrix} 1 & 0 \\ -3 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 1 & -2 \\ 0 & 8 \end{bmatrix}. \quad (4.55)$$

两边左乘 E_{21}^{-1} , 就得到 $A = E_{21}^{-1}U$ 。 E_{21}^{-1} 是什么? E_{21} 做的是“第二行减去 3 倍第一行”, 逆操作就是“第二行加上 3 倍第一行”, 所以

$$E_{21}^{-1} = \begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix}. \quad (4.56)$$

乘子 3 在 E_{21} 里带着负号坐在 $(2, 1)$ 位置, 到了逆矩阵里变回正号, 位置不变。记

$$L = E_{21}^{-1} = \begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix}, \quad (4.57)$$

这是一个主对角线全为 1、对角线以上全为零的**下三角矩阵**。真的乘回去验证:

$$LU = \begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 \\ 0 & 8 \end{bmatrix} = \begin{bmatrix} 1 & -2 \\ 3 & -6 + 8 \end{bmatrix} = \begin{bmatrix} 1 & -2 \\ 3 & 2 \end{bmatrix} = A. \quad (4.58)$$

原矩阵完好无损地被拆成了一个下三角矩阵乘一个上三角矩阵。

一般情形照此办理。假设消元过程中不需要交换行, 经过若干消元矩阵后

$$E_k \cdots E_2 E_1 A = U. \quad (4.59)$$

于是

$$A = (E_k \cdots E_2 E_1)^{-1} U = E_1^{-1} E_2^{-1} \cdots E_k^{-1} U. \quad (4.60)$$

每个 E_{ij}^{-1} 只是把对应位置上的 $-\ell_{ij}$ 变回 $+\ell_{ij}$; 它们乘起来仍是下三角矩阵 L , 主对角线上全是 1, 而消元中使用的乘子 ℓ_{ij} 恰好出现在 L 的第 (i, j) 个位置——不需要额外计算, 消元时顺手记下即可。因此

$$\boxed{A = LU.} \quad (4.61)$$

其中

$$L = \text{下三角矩阵}, \quad U = \text{上三角矩阵}. \quad (4.62)$$

这个分解把求解

$$A\mathbf{x} = \mathbf{b} \quad (4.63)$$

拆成两个三角系统:

$$L\mathbf{c} = \mathbf{b}, \quad U\mathbf{x} = \mathbf{c}. \quad (4.64)$$

第一步从上往下逐个解出 $c_1, c_2, \dots$, 称为**向前代入**; 第二步就是已经熟悉的回代。用同一个例子把两步走完。先解 $L\mathbf{c} = \mathbf{b}$:

$$\begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 11 \end{bmatrix} \implies c_1 = 1, \quad 3 \times 1 + c_2 = 11, \quad c_2 = 8. \quad (4.65)$$

再解 $U\mathbf{x} = \mathbf{c}$:

$$\begin{bmatrix} 1 & -2 \\ 0 & 8 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 1 \\ 8 \end{bmatrix} \implies 8y = 8, \quad y = 1; \quad x - 2 \times 1 = 1, \quad x = 3. \quad (4.66)$$

结果与前面直接消元得到的 (3, 1) 完全一致——这本来就是把同样的行变换换了一种记账方式: 乘子记进 L , 上三角系统记进 U 。真正的好处在于重复使用: 若同一个 A 需要对应很多不同的 $\mathbf{b}$, 只需把 LU 分解做一次, 之后每个 $\mathbf{b}$ 只走两次代入, 不必从头消元。

还可以把 U 的主元单独提出来。例子里

$$\begin{bmatrix} 1 & -2 \\ 0 & 8 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 8 \end{bmatrix} \begin{bmatrix} 1 & -2 \\ 0 & 1 \end{bmatrix}, \quad (4.67)$$

主元 1, 8 进入一个对角矩阵 D , 剩下的上三角矩阵对角线上全为 1, 仍记作 U 。于是分解细化为

$$A = LDU, \quad (4.68)$$

三个因子各司其职: L 存乘子, D 存主元, U 存消元后的形状。对于对称矩阵, 这个分解会进一步变成

$$S = LDL^T. \quad (4.69)$$

以上都假设消元不需要换行。如果消元过程中必须交换行, 就把所有行交换集到一个置换矩阵 P 中, 相当于先把行顺序排好, 再做不换行的消元。对任意可逆矩阵, 总能通过适当的行排列得到

$$\boxed{PA = LU}. \quad (4.70)$$

实际数值计算中, 即使当前主元并不为零, 只要它太小, 也常常主动交换行把更大的数换上来——用太小的主元当除数会放大舍入误差。这里先只保留结构上的认识: 消元对应三角分解, 行交换对应置换矩阵。

5 向量空间、解空间与秩

前几章主要围绕一个问题：给定方程 $A\mathbf{x} = \mathbf{b}$ ，怎样把它的解求出来。从这一章开始，我们把视角抬高一层：不再只盯着一个方程，而是把所有可能的输入 $\mathbf{x}$ 、所有可能的输出 $A\mathbf{x}$ 、以及方程的全部解分别看成一个个集合，追问它们是什么形状、有多大、彼此之间又有什么关系。回答这些问题，需要本章的核心概念——向量空间与子空间。

5.1 向量空间、子空间与张成

第 1 章里我们一直在 $\mathbb{R}^n$ 中工作：向量可以相加、可以乘标量，运算结果仍然落回 $\mathbb{R}^n$ 。这样一个配好了加法与数乘、并且对这两种运算封闭的集合，称为一个**向量空间**。 $\mathbb{R}^n$ 是最典型的向量空间，但“向量”并不只是一列实数：在合适的加法与数乘下，矩阵、函数也能组成向量空间。本章只关心 $\mathbb{R}^n$ 以及它内部的子空间。

若集合 $S \subseteq \mathbb{R}^n$ 满足：

1. $\mathbf{0} \in S$;
2. 对任意 $\mathbf{u}, \mathbf{v} \in S$ ，都有 $\mathbf{u} + \mathbf{v} \in S$;
3. 对任意 $\mathbf{u} \in S$ 和标量 c ，都有 $c\mathbf{u} \in S$ ，

那么 S 是 $\mathbb{R}^n$ 的一个**子空间**。后两条也可以合并成一句话：子空间必须包含其中向量的一切线性组合。

光有三条规则还不够直观，拿 $\mathbb{R}^2$ 中的直线具体判断一下。先看过原点的直线，例如 $y = 2x$ ，即所有形如

$$t \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad t \in \mathbb{R} \quad (5.1)$$

的向量构成的集合 L 。逐条验证：

- 取 $t = 0$ 得 $\mathbf{0} \in L$ ，第一条成立；
- 任取 L 中两个向量 $\mathbf{u} = s(1, 2)^T$ 与 $\mathbf{v} = t(1, 2)^T$ ，则

$$\mathbf{u} + \mathbf{v} = (s + t) \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad (5.2)$$

仍是 $(1, 2)^T$ 的倍数，仍在 L 中，第二条成立；

- 对任意标量 c ，

$$c\mathbf{u} = cs \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad (5.3)$$

也仍在 L 中，第三条成立。

三条都满足，所以过原点的直线是 $\mathbb{R}^2$ 的子空间。

再把这条直线向上平移一个单位, 得到 $y = 2x + 1$, 它就不是子空间了。第一条就过不了: 把原点代入直线方程, $0 \neq 2 \cdot 0 + 1$, 所以 $\mathbf{0}$ 不在其中。即使不看原点, 封闭性也出了问题: $(0, 1)^T$ 与 $(1, 3)^T$ 都满足直线方程, 但它们的和

$$\begin{bmatrix} 0 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \end{bmatrix} \quad (5.4)$$

不满足 $4 = 2 \cdot 1 + 1$, 已经跑到直线外面去了。平移破坏了子空间的结构。

同样的判断方法适用于任何集合: $\mathbb{R}^3$ 中过原点的直线和平面都是子空间; 只含零向量的 $\{\mathbf{0}\}$ 和整个 $\mathbb{R}^n$ 则是两个最极端的子空间。实际检查时, 第一条往往最先暴露问题。

第 1 章已经强调过: 不要只看某一个线性组合, 而要看所有可能的线性组合。给定若干向量 $\mathbf{v}_1, \dots, \mathbf{v}_k$, 它们的所有线性组合

$$c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k \quad (5.5)$$

构成的集合称为这些向量的**张成空间**, 记为

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}. \quad (5.6)$$

它确实是一个子空间: 全部系数取零得到零向量; 两个线性组合相加、一个线性组合乘上标量, 得到的仍然是线性组合。而且它是包含这些向量的最小子空间——任何包含 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 的子空间, 按定义都必须包含它们的一切线性组合。

把矩阵按列拆开。若

$$A = \begin{bmatrix} \mathbf{a}_1 & \dots & \mathbf{a}_n \end{bmatrix}, \quad (5.7)$$

则 A 的所有列向量的线性组合构成**列空间**

$$C(A) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_n\}. \quad (5.8)$$

第 3 章的列观点告诉我们

$$A\mathbf{x} = x_1 \mathbf{a}_1 + \dots + x_n \mathbf{a}_n, \quad (5.9)$$

即 $A\mathbf{x}$ 遍历的恰好是列向量的所有线性组合, 所以列空间也可以写成

$$C(A) = \{A\mathbf{x} : \mathbf{x} \in \mathbb{R}^n\}. \quad (5.10)$$

这立刻给出一个重要结论:

$$\boxed{A\mathbf{x} = \mathbf{b} \text{ 有解} \iff \mathbf{b} \in C(A).} \quad (5.11)$$

看一个 2×2 的例子:

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix}. \quad (5.12)$$

它的两列共线, $C(A)$ 只是 $\mathbb{R}^2$ 中过原点、沿 $(1, 3)^T$ 方向的那条直线。若 $\mathbf{b} = (2, 6)^T$, 它在这条直线上, 方程有解 (例如 $\mathbf{x} = (2, 0)^T$); 若 $\mathbf{b} = (2, 7)^T$, 它不在列空间中, 方程无解。是否有解, 完全取决于 $\mathbf{b}$ 落不落在这个子空间里。

5.2 零空间、主元变量与自由变量

列空间收集的是所有可能的输出；零空间则收集所有被 A 变成零的输入。方程

$$A\mathbf{x} = \mathbf{0} \quad (5.13)$$

的全部解构成 A 的零空间

$$N(A) = \{\mathbf{x} \in \mathbb{R}^n : A\mathbf{x} = \mathbf{0}\}. \quad (5.14)$$

它一定是 $\mathbb{R}^n$ 的子空间，逐条验证： $A\mathbf{0} = \mathbf{0}$ ，所以 $\mathbf{0} \in N(A)$ ；若 $A\mathbf{u} = \mathbf{0}$ 且 $A\mathbf{v} = \mathbf{0}$ ，则

$$A(\mathbf{u} + \mathbf{v}) = A\mathbf{u} + A\mathbf{v} = \mathbf{0} + \mathbf{0} = \mathbf{0}, \quad (5.15)$$

即 $\mathbf{u} + \mathbf{v} \in N(A)$ ；若 $A\mathbf{u} = \mathbf{0}$ ，则对任意标量 c ，

$$A(c\mathbf{u}) = cA\mathbf{u} = c\mathbf{0} = \mathbf{0}, \quad (5.16)$$

即 $c\mathbf{u} \in N(A)$ 。三条规则全部满足。

为了把零空间系统地描述出来，用第 4 章的消元。先把 A 化成行阶梯形，再继续做 Gauss-Jordan 消元：把每个主元化为 1，并把主元所在列的其余元素也消成 0。最终得到的矩阵称为 A 的行最简阶梯形矩阵，记为

$$R = \text{rref}(A). \quad (5.17)$$

行变换只是对各方程做交换、倍乘与加减，不改变齐次方程的解，因此

$$N(A) = N(R). \quad (5.18)$$

拿一个 2×4 的矩阵从头算到尾：

$$A = \begin{bmatrix} 1 & 3 & 3 & 2 \\ 2 & 6 & 9 & 7 \end{bmatrix}. \quad (5.19)$$

第一步，第二行减去第一行的 2 倍：

$$\begin{bmatrix} 1 & 3 & 3 & 2 \\ 0 & 0 & 3 & 3 \end{bmatrix}. \quad (5.20)$$

第一列的主元是 1；第二列因为是第一列的 3 倍，消元后整列变成了零，所以第二个主元落在第三列。第二步，第二行除以 3，把这个主元化为 1：

$$\begin{bmatrix} 1 & 3 & 3 & 2 \\ 0 & 0 & 1 & 1 \end{bmatrix}. \quad (5.21)$$

第三步，第一行减去第二行的 3 倍，把主元上方的 3 也消成 0：

$$R = \text{rref}(A) = \begin{bmatrix} 1 & 3 & 0 & -1 \\ 0 & 0 & 1 & 1 \end{bmatrix}. \quad (5.22)$$

主元落在第 1、3 列，这两列称为主元列，对应的变量 x_1, x_3 称为主元变量；第 2、4 列没有主元，称为自由列，对应的变量 x_2, x_4 称为自由变量，取值不受任何限制。

把 $R\mathbf{x} = \mathbf{0}$ 按行写出来：

$$x_1 + 3x_2 - x_4 = 0, \quad x_3 + x_4 = 0. \quad (5.23)$$

自由变量一旦取定，这两个方程就把主元变量唯一确定。每次只让一个自由变量取 1，其余取 0，解出主元变量，得到的解称为一个特殊解。

先取 $x_2 = 1, x_4 = 0$ 。第二个方程给出 $x_3 = 0$ ，代入第一个方程给出 $x_1 = -3$ ，于是

$$\mathbf{s}_1 = \begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \end{bmatrix}. \quad (5.24)$$

再取 $x_2 = 0, x_4 = 1$ 。第二个方程给出 $x_3 = -1$ ，代入第一个方程给出 $x_1 = 1$ ，于是

$$\mathbf{s}_2 = \begin{bmatrix} 1 \\ 0 \\ -1 \\ 1 \end{bmatrix}. \quad (5.25)$$

代回原来的 A 检验（注意用 A 本身，而不是 R ）：

$$A\mathbf{s}_1 = \begin{bmatrix} 1 \cdot (-3) + 3 \cdot 1 + 3 \cdot 0 + 2 \cdot 0 \\ 2 \cdot (-3) + 6 \cdot 1 + 9 \cdot 0 + 7 \cdot 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad (5.26)$$

$$A\mathbf{s}_2 = \begin{bmatrix} 1 \cdot 1 + 3 \cdot 0 + 3 \cdot (-1) + 2 \cdot 1 \\ 2 \cdot 1 + 6 \cdot 0 + 9 \cdot (-1) + 7 \cdot 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \quad (5.27)$$

两个特殊解确实都在零空间里。

这两个特殊解的线性组合

$$\mathbf{x} = x_2\mathbf{s}_1 + x_4\mathbf{s}_2 = x_2 \begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \end{bmatrix} + x_4 \begin{bmatrix} 1 \\ 0 \\ -1 \\ 1 \end{bmatrix} \quad (5.28)$$

给出了 $A\mathbf{x} = \mathbf{0}$ 的全部解。一方面， $N(A)$ 是子空间，特殊解的任何线性组合仍在其中；另一方面，零空间中任取一个向量，它的第 2、4 分量就是它自己的自由变量取值，用这两个数作系数去组合 $\mathbf{s}_1, \mathbf{s}_2$ ，第 2、4 分量已经吻合，而主元变量由自由变量唯一决定，其余分量也必然吻合，组合出来的正是它自己。

一般地，如果 A 有 n 列、 r 个主元，那么有

$$n - r \quad (5.29)$$

个自由变量，对应 $n - r$ 个特殊解 $\mathbf{s}_1, \dots, \mathbf{s}_{n-r}$ ，它们张成整个零空间：

$$N(A) = \text{span}\{\mathbf{s}_1, \dots, \mathbf{s}_{n-r}\}. \quad (5.30)$$

这些特殊解还线性无关：每个特殊解在“自己那个”自由变量的位置上为 1、其余自由变量的位置上为 0，若它们的某个线性组合等于零向量，看这些位置就知道每个系数都必须为零。因此特殊解构成零空间的一组基，零空间的维数正好等于自由变量的个数。上面的例子中 $n = 4$ ， $r = 2$ ，零空间是 $\mathbb{R}^4$ 中的一个二维子空间。

主元的个数

$$r \quad (5.31)$$

称为矩阵的**秩**，记为

$$\text{rank}(A) = r. \quad (5.32)$$

秩既等于主元列的个数，也等于主元行的个数，所以对 $m \times n$ 矩阵总有 $r \leq m$ 且 $r \leq n$ 。秩衡量的是矩阵真正包含多少个独立方向：行数与列数只是“看上去”的大小，秩才是消元之后剩下的实质。

5.3 $A\mathbf{x} = \mathbf{b}$ 的完整解

回到非齐次方程

$$A\mathbf{x} = \mathbf{b}. \quad (5.33)$$

如果它有解，那么所有解都可以写成

$$\boxed{\mathbf{x} = \mathbf{x}_p + \mathbf{x}_n}, \quad (5.34)$$

其中

$$A\mathbf{x}_p = \mathbf{b} \quad (5.35)$$

是随便找到的一个**特解**，而

$$A\mathbf{x}_n = \mathbf{0} \quad (5.36)$$

取遍零空间中的一切向量。

公式 (5.34) 说了两件事。第一，特解加上任意零空间解仍然是解：

$$A(\mathbf{x}_p + \mathbf{x}_n) = A\mathbf{x}_p + A\mathbf{x}_n = \mathbf{b} + \mathbf{0} = \mathbf{b}. \quad (5.37)$$

第二，它不会漏掉任何解：若 $\mathbf{x}'$ 也满足 $A\mathbf{x}' = \mathbf{b}$ ，与 $A\mathbf{x}_p = \mathbf{b}$ 相减得

$$A(\mathbf{x}' - \mathbf{x}_p) = \mathbf{b} - \mathbf{b} = \mathbf{0}, \quad (5.38)$$

即 $\mathbf{x}' - \mathbf{x}_p$ 属于零空间，把它记为 $\mathbf{x}_n$ ，就有 $\mathbf{x}' = \mathbf{x}_p + \mathbf{x}_n$ 。两步合起来说明： $A\mathbf{x} = \mathbf{b}$ 的解集就是把零空间整体平移到 $\mathbf{x}_p$ 处得到的集合。几何上，解集是一条（高维的）直线或一个平面，但一般不经过原点——这又一次解释了本章第一节里平移后的直线为什么不是子空间。

实际求特解时，对增广矩阵

$$[A \mid \mathbf{b}] \quad (5.39)$$

做与上一节完全相同的行化简，得到

$$[R \mid \mathbf{d}]. \quad (5.40)$$

若 R 中某一行已经全为零，而 $\mathbf{d}$ 的对应分量却非零，这一行读作

$$0 = c, \quad c \neq 0, \quad (5.41)$$

方程无解——这正是 $\mathbf{b} \notin C(A)$ 的情形。若所有零行右侧也都是零，方程相容。此时一个方便的特解是：先把全部自由变量设为零，再由 $R\mathbf{x} = \mathbf{d}$ 直接读出主元变量。

继续用上一节的矩阵，取 $\mathbf{b} = (1, 5)^\top$ 。同样的三步行变换作用在增广矩阵上，最后一列跟着一起变：

$$\begin{bmatrix} 1 & 3 & 3 & 2 & 1 \\ 2 & 6 & 9 & 7 & 5 \end{bmatrix} \longrightarrow \begin{bmatrix} 1 & 3 & 3 & 2 & 1 \\ 0 & 0 & 3 & 3 & 3 \end{bmatrix} \quad (5.42)$$

$$\longrightarrow \begin{bmatrix} 1 & 3 & 3 & 2 & 1 \\ 0 & 0 & 1 & 1 & 1 \end{bmatrix} \longrightarrow \begin{bmatrix} 1 & 3 & 0 & -1 & -2 \\ 0 & 0 & 1 & 1 & 1 \end{bmatrix}, \quad (5.43)$$

最后一列就是 $\mathbf{d} = (-2, 1)^\top$ 。令自由变量 $x_2 = x_4 = 0$ ，由第二行读出 $x_3 = 1$ ，由第一行读出 $x_1 = -2$ ，得到特解

$$\mathbf{x}_p = \begin{bmatrix} -2 \\ 0 \\ 1 \\ 0 \end{bmatrix}. \quad (5.44)$$

检验：

$$A\mathbf{x}_p = \begin{bmatrix} 1 \cdot (-2) + 3 \cdot 0 + 3 \cdot 1 + 2 \cdot 0 \\ 2 \cdot (-2) + 6 \cdot 0 + 9 \cdot 1 + 7 \cdot 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \end{bmatrix} = \mathbf{b}. \quad (5.45)$$

再加上上一节求出的整个零空间，完整解为

$$\mathbf{x} = \mathbf{x}_p + x_2 \mathbf{s}_1 + x_4 \mathbf{s}_2 = \begin{bmatrix} -2 \\ 0 \\ 1 \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \end{bmatrix} + x_4 \begin{bmatrix} 1 \\ 0 \\ -1 \\ 1 \end{bmatrix}, \quad x_2, x_4 \in \mathbb{R}. \quad (5.46)$$

无解的情形前面也已经见过：本章第一节那个 2×2 矩阵配上 $\mathbf{b} = (2, 7)^\top$ ，增广矩阵

$$\begin{bmatrix} 1 & 2 & 2 \\ 3 & 6 & 7 \end{bmatrix} \longrightarrow \begin{bmatrix} 1 & 2 & 2 \\ 0 & 0 & 1 \end{bmatrix}, \quad (5.47)$$

第二行读作 $0 = 1$ ，方程无解。这和“ $\mathbf{b}$ 不在列空间中”是同一件事的两种说法。

根据 $m \times n$ 矩阵的秩 r ，可以把解的情况归纳为四类：

秩的情形	矩阵形状	零空间	$A\mathbf{x} = \mathbf{b}$
$r = m = n$	方阵可逆	$\{\mathbf{0}\}$	每个 $\mathbf{b}$ 有唯一解
$r = n < m$	满列秩	$\{\mathbf{0}\}$	有解时唯一，否则无解
$r = m < n$	满行秩	$\dim N(A) = n - m$	每个 $\mathbf{b}$ 都有无穷多解
$r < m, r < n$	秩亏	$\dim N(A) = n - r$	无解或无穷多解

(5.48)

这张表把“是否有解”和“解是否唯一”分开了：是否有解取决于 $\mathbf{b}$ 是否在列空间中；是否唯一取决于零空间里是否只有零向量。我们反复使用的 2×4 矩阵属于第三行： $r = m = 2 < n = 4$ ，所以每个 $\mathbf{b}$ 都有解，且解里带着两个自由参数，绝不唯一。

5.4 线性无关、基与维数

第 1 章已经给出过判别方式：向量 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 线性无关，当且仅当

$$c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k = \mathbf{0} \quad (5.49)$$

只有

$$c_1 = \dots = c_k = 0 \quad (5.50)$$

这一组解。把这些向量作为矩阵的列，即

$$A = \begin{bmatrix} \mathbf{v}_1 & \dots & \mathbf{v}_k \end{bmatrix}, \quad (5.51)$$

判别方程就变成了 $A\mathbf{c} = \mathbf{0}$ ，于是线性无关等价于

$$N(A) = \{\mathbf{0}\}. \quad (5.52)$$

用秩的语言说：列向量线性无关，当且仅当 A 没有自由列，即 $r = k$ 。

若一组向量既线性无关，又能够张成子空间 S ，则称它们构成 S 的一组**基**。基的两个条件分别排除了两种问题：张成保证“没有漏掉方向”，线性无关保证“没有多余方向”。例如 $(1, 0)^T$ 与 $(0, 1)^T$ 是 $\mathbb{R}^2$ 的一组基， $(1, 2)^T$ 与 $(2, 1)^T$ 也是——基并不唯一，但任意一组基都恰好含两个向量。

这不是巧合。同一空间的任意两组基所含向量个数都相同，这个数就定义为该空间的**维数**。例如

$$\dim \mathbb{R}^n = n. \quad (5.53)$$

若 A 的秩为 r ，那么它的列空间维数为

$$\dim C(A) = r. \quad (5.54)$$

理由是：消元不改变列之间的线性关系，因为 $A\mathbf{x} = \mathbf{0}$ 与 $R\mathbf{x} = \mathbf{0}$ 的解完全相同，同一组系数在 A 的各列上成立，当且仅当它在 R 的各列上成立。而 R 的主元列是互不

相同的坐标单位向量，线性无关； R 的每个自由列都能由主元列组合出来，组合系数就写在该自由列的分量里。把这两条传回 A ： A 的主元列线性无关，且每个自由列都能由它们组合，因此 A 的 r 个主元列恰好构成 $C(A)$ 的一组基。

零空间这边已经更清楚了： $n - r$ 个特殊解既张成 $N(A)$ 又线性无关，它们就是零空间的一组基，所以

$$\dim N(A) = n - r. \quad (5.55)$$

零空间的维数也称为矩阵的**零度**，记为 $\text{nullity}(A)$ 。把秩与零度加起来，得到最基本的秩-零度关系：

$$\text{rank}(A) + \text{nullity}(A) = n. \quad (5.56)$$

这里 n 是输入空间 $\mathbb{R}^n$ 的维数。这个等式其实很自然： n 个变量里，每个要么是主元变量、要么是自由变量；秩数的是主元，零度数的是自由变量，两者恰好把 n 瓜分干净。

5.5 四个基本子空间

对于一个 $m \times n$ 矩阵 A ，除了列空间和零空间之外，还要同时考虑 A^T 。 A^T 的列就是 A 的行，所以 $C(A^T)$ 称为 A 的行空间； A^T 的零空间 $N(A^T)$ 则称为 A 的左零空间。这样一共得到四个基本子空间：

1. 列空间

$$C(A) \subseteq \mathbb{R}^m, \quad \dim C(A) = r; \quad (5.57)$$

2. 零空间

$$N(A) \subseteq \mathbb{R}^n, \quad \dim N(A) = n - r; \quad (5.58)$$

3. 行空间

$$C(A^T) \subseteq \mathbb{R}^n, \quad \dim C(A^T) = r; \quad (5.59)$$

4. 左零空间

$$N(A^T) \subseteq \mathbb{R}^m, \quad \dim N(A^T) = m - r. \quad (5.60)$$

“左零空间”这个名字的来源：方程 $A^T \mathbf{y} = \mathbf{0}$ 两边转置后变成 $\mathbf{y}^T A = \mathbf{0}^T$ ， $\mathbf{y}$ 乘在 A 的左边。

行空间和列空间的维数相同，都等于秩 r 。这件事把“有多少个独立行”和“有多少个独立列”统一成了同一个数。原因并不神秘：行变换只是对行做线性组合，不会张出新的方向，所以 A 与 R 的行空间相同；而 R 的 r 个非零行各带一个主元，主元位置互不相同，它们线性无关，正好构成行空间的一组基。

消元能够直接提供这些空间的基，但要留心取基的位置。对于列空间，应选取**原矩阵 A 的主元列**作为基，因为行变换一般会改变列空间本身：本章第一节那个 2×2 矩阵化简后是

$$R = \begin{bmatrix} 1 & 2 \\ 0 & 0 \end{bmatrix}, \quad (5.61)$$

$C(A)$ 是沿 $(1, 3)^T$ 方向的直线，而 $C(R)$ 是 x 轴，已经不是同一个子空间。对于行空间，可以取行最简梯形矩阵 R 的非零行作为基；对于零空间，则取 $R\mathbf{x} = \mathbf{0}$ 的特殊解作为基。左零空间可以通过解

$$A^T \mathbf{y} = \mathbf{0} \quad (5.62)$$

得到，做法与求零空间完全一样。

用贯穿本章的 2×4 矩阵把四个空间一起写出来。列空间： $r = 2 = m$ ，已经满秩，所以 $C(A) = \mathbb{R}^2$ 。零空间： $N(A) = \text{span}\{\mathbf{s}_1, \mathbf{s}_2\}$ ，是 $\mathbb{R}^4$ 中的二维子空间。行空间：由 R 的两个非零行 $(1, 3, 0, -1)$ 与 $(0, 0, 1, 1)$ 张成，也是 $\mathbb{R}^4$ 中的二维子空间。左零空间： A^T 是 4×2 矩阵，秩为 2，没有自由变量，所以 $N(A^T) = \{\mathbf{0}\}$ ，维数 $m - r = 0$ 。四个维数 2, 2, 2, 0 正好对应 $r, n - r, r, m - r$ 。




图 2: 四个基本子空间及其维数

图中两个垂直关系将在下一节正式说明。它们把矩阵的输入空间和输出空间分别拆成两个互相正交的部分。

6 正交、投影与最小二乘

第 2 章用点积定义了两个向量的正交： $\mathbf{v} \cdot \mathbf{w} = 0$ 。上一章又给每个矩阵配了四个基本子空间，并预告了其中的两组垂直关系。本章先把这两组垂直关系严格证出来，然后做一件更实用的事：当一个向量落在某个子空间之外时，在这个子空间里找离它最近的点。找最近点的过程就是投影，而投影又直接给出处理无解方程组的办法——最小二乘。

6.1 正交子空间与正交补

两个向量正交，说的是它们点积为零。把这句话搬到子空间上：若子空间 $V, W \subseteq \mathbb{R}^n$ 满足，对任意

$$\mathbf{v} \in V, \quad \mathbf{w} \in W, \quad (6.1)$$

都有

$$\mathbf{v}^T \mathbf{w} = 0, \quad (6.2)$$

则称 V 与 W 是**正交子空间**。也就是说，从一个子空间里随便取一个向量，都和从另一个子空间里随便取的向量垂直。

比如在 $\mathbb{R}^3$ 中， z 轴与 xy 平面就是一对正交子空间： z 轴上的向量 $(0, 0, c)$ 与平面内任意向量 $(x, y, 0)$ 的点积都是 0。

上一章最重要的垂直关系，发生在行空间与零空间之间。现在把推导逐行写出来。设 $\mathbf{x} \in N(A)$ ，即

$$A\mathbf{x} = \mathbf{0}. \quad (6.3)$$

把 A 按行来看。记 A 的第 1 行到第 m 行依次为行向量 $\mathbf{r}_1^\top, \dots, \mathbf{r}_m^\top$ ，那么矩阵乘向量 $A\mathbf{x}$ 的第 i 个分量，就是第 i 行与 $\mathbf{x}$ 的点积：

$$A\mathbf{x} = \begin{bmatrix} \mathbf{r}_1^\top \mathbf{x} \\ \mathbf{r}_2^\top \mathbf{x} \\ \vdots \\ \mathbf{r}_m^\top \mathbf{x} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}. \quad (6.4)$$

右边是零向量，意味着左边每一个分量都为零：

$$\mathbf{r}_1^\top \mathbf{x} = 0, \quad \mathbf{r}_2^\top \mathbf{x} = 0, \quad \dots, \quad \mathbf{r}_m^\top \mathbf{x} = 0. \quad (6.5)$$

所以 $A\mathbf{x} = \mathbf{0}$ 的真正含义是： $\mathbf{x}$ 与 A 的每一行都正交。

行空间是各行的一切线性组合，而点积对线性组合可以逐项分配：

$$(c_1 \mathbf{r}_1 + \dots + c_m \mathbf{r}_m)^\top \mathbf{x} = c_1 \mathbf{r}_1^\top \mathbf{x} + \dots + c_m \mathbf{r}_m^\top \mathbf{x} = 0. \quad (6.6)$$

因此 $\mathbf{x}$ 垂直于整个行空间。这就证明了

$$\boxed{C(A^\top) \perp N(A)}. \quad (6.7)$$

看个具体的矩阵。取

$$A = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}. \quad (6.8)$$

逐行检验点积：

$$(1, 0, -1) \cdot (1, 1, 1) = 1 + 0 - 1 = 0, \quad (0, 1, -1) \cdot (1, 1, 1) = 0 + 1 - 1 = 0, \quad (6.9)$$

所以 $A\mathbf{x} = \mathbf{0}$ ，即 $\mathbf{x} \in N(A)$ ，而它确实与两行都垂直。

把 A 换成 $A^\top$ ，同样的结论再套一次： $A^\top$ 的行空间是 $C(A)$ ，零空间是 $N(A^\top)$ ，于是

$$\boxed{C(A) \perp N(A^\top)}. \quad (6.10)$$

这两对子空间不只是互相垂直，它们还恰好把全空间拼满。先看一个事实：正交子空间的公共向量只有零向量。若 $\mathbf{x}$ 同时属于 V 与 W ，那么它与它自己正交，

$$\mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|^2 = 0, \quad (6.11)$$

长度为 0 的向量只有零向量，所以 $\mathbf{x} = \mathbf{0}$ 。再看维数：上一章算过，在 $\mathbb{R}^n$ 中

$$\dim C(A^T) = r, \quad \dim N(A) = n - r, \quad (6.12)$$

加起来正好是 n 。两部分没有重叠，维数又刚好拼满，于是任意

$$\mathbf{x} \in \mathbb{R}^n \quad (6.13)$$

都能唯一地拆成

$$\mathbf{x} = \mathbf{x}_{\text{row}} + \mathbf{x}_{\text{null}}, \quad (6.14)$$

其中

$$\mathbf{x}_{\text{row}} \in C(A^T), \quad \mathbf{x}_{\text{null}} \in N(A). \quad (6.15)$$

唯一性可以从基看出来：把行空间的一组基（ r 个向量）与零空间的一组基（ $n - r$ 个向量）放在一起，共 n 个向量。若它们的某个线性组合等于零向量，则其中行空间那一部分等于零空间那一部分的相反数，它同时落在两个子空间里，只能是 $\mathbf{0}$ ，于是所有系数都为 0。这 n 个向量线性无关，构成 $\mathbb{R}^n$ 的一组基，每个 $\mathbf{x}$ 的分解自然唯一。

满足这种关系的两个子空间互为**正交补**：一个子空间恰好由所有与另一个子空间正交的向量组成。事实上，逐行展开的那段推导已经说明，与 $C(A^T)$ 正交的全部向量正好构成 $N(A)$ 。所以 $C(A^T)$ 与 $N(A)$ 互为正交补， $C(A)$ 与 $N(A^T)$ 也互为正交补。

同样，在 $\mathbb{R}^m$ 中任意

$$\mathbf{b} \in \mathbb{R}^m \quad (6.16)$$

都能唯一写成

$$\mathbf{b} = \mathbf{p} + \mathbf{e}, \quad (6.17)$$


其中

$$\mathbf{p} \in C(A), \quad \mathbf{e} \in N(A^T), \quad \mathbf{p} \perp \mathbf{e}. \quad (6.18)$$

本章剩下的内容都建立在这个分解上： $\mathbf{p}$ 是 $\mathbf{b}$ 在列空间中的投影， $\mathbf{e}$ 是垂直于列空间的误差部分。

6.2 投影到一条直线

先看最简单的问题：给定从原点出发的向量 $\mathbf{b}$ ，以及一条过原点、由非零向量 $\mathbf{a}$ 张成的直线，直线上哪个点离 $\mathbf{b}$ 的终点最近？

图 3: 把 $\mathbf{b}$ 投影到 $\mathbf{a}$ 张成的直线上

直觉已经给出了答案：从 $\mathbf{b}$ 的终点向直线作垂线，垂足就是最近的点。这个垂足称为 $\mathbf{b}$ 在这条直线上的**投影**，记为 $\mathbf{p}$ 。下面把 $\mathbf{p}$ 算出来，每一步都写清楚。

垂足 $\mathbf{p}$ 在直线上，所以它是 $\mathbf{a}$ 的某个倍数：

$$\mathbf{p} = \hat{x}\mathbf{a}. \quad (6.19)$$

误差向量

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = \mathbf{b} - \hat{x}\mathbf{a} \quad (6.20)$$

与直线垂直，也就是与 $\mathbf{a}$ 正交。用点积写出来：

$$\mathbf{a}^\top(\mathbf{b} - \hat{x}\mathbf{a}) = 0. \quad (6.21)$$

把括号分配开：

$$\mathbf{a}^\top\mathbf{b} - \hat{x}\mathbf{a}^\top\mathbf{a} = 0. \quad (6.22)$$

把含 $\hat{x}$ 的项移到右边：

$$\hat{x}\mathbf{a}^\top\mathbf{a} = \mathbf{a}^\top\mathbf{b}. \quad (6.23)$$

因为 $\mathbf{a} \neq \mathbf{0}$ ， $\mathbf{a}^\top\mathbf{a} = \|\mathbf{a}\|^2$ 是一个正数，可以除过去：

$$\hat{x} = \frac{\mathbf{a}^\top\mathbf{b}}{\mathbf{a}^\top\mathbf{a}}. \quad (6.24)$$

代回 $\mathbf{p} = \hat{x}\mathbf{a}$ ，得到投影公式 (6.25)

$$\boxed{\mathbf{p} = \frac{\mathbf{a}^\top\mathbf{b}}{\mathbf{a}^\top\mathbf{a}}\mathbf{a}.} \quad (6.25)$$

拿具体数字算一遍。取

$$\mathbf{a} = (1, 1, 1)^\top, \quad \mathbf{b} = (1, 2, 3)^\top. \quad (6.26)$$

先算两个点积：

$$\mathbf{a}^\top\mathbf{b} = 1 + 2 + 3 = 6, \quad \mathbf{a}^\top\mathbf{a} = 1 + 1 + 1 = 3, \quad (6.27)$$

所以

$$\hat{x} = \frac{6}{3} = 2, \quad \mathbf{p} = 2\mathbf{a} = (2, 2, 2)^\top. \quad (6.28)$$

误差是

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = (-1, 0, 1)^\top. \quad (6.29)$$

它是否真的与 $\mathbf{a}$ 垂直？做点积检验：

$$\mathbf{a}^\top \mathbf{e} = -1 + 0 + 1 = 0. \quad (6.30)$$

确实垂直，答案经得起检查。

再换个角度看公式 (6.25)。 $\mathbf{a}^\top \mathbf{b}$ 是标量，可以改变乘法结合的顺序：

$$\mathbf{p} = \mathbf{a} \frac{\mathbf{a}^\top \mathbf{b}}{\mathbf{a}^\top \mathbf{a}} = \frac{\mathbf{a} \mathbf{a}^\top}{\mathbf{a}^\top \mathbf{a}} \mathbf{b}, \quad (6.31)$$

这里用到 $\mathbf{a}(\mathbf{a}^\top \mathbf{b}) = (\mathbf{a} \mathbf{a}^\top) \mathbf{b}$ ：左边是向量乘标量，右边是矩阵乘向量，逐分量展开后完全相同。这说明投影是一个矩阵作用在 $\mathbf{b}$ 上： $\mathbf{p} = P \mathbf{b}$ ，其中

$$P = \frac{\mathbf{a} \mathbf{a}^\top}{\mathbf{a}^\top \mathbf{a}}. \quad (6.32)$$

注意分子 $\mathbf{a} \mathbf{a}^\top$ 是 $n \times n$ 矩阵（列乘行），分母 $\mathbf{a}^\top \mathbf{a}$ 是标量（行乘列），两者的顺序不能颠倒。

用上面的例子， $\mathbf{a} \mathbf{a}^\top$ 是全 1 矩阵，所以

$$P = \frac{1}{3} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}, \quad P \mathbf{b} = \frac{1}{3} \begin{bmatrix} 6 \\ 6 \\ 6 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} = \mathbf{p}, \quad (6.33)$$

与刚才直接代入公式 (6.25) 的结果一致。

投影矩阵有两条标志性性质。第一条：

$$P^2 = P. \quad (6.34)$$

直接代入公式 (6.30) 验证：

$$P^2 = \frac{\mathbf{a} \mathbf{a}^\top}{\mathbf{a}^\top \mathbf{a}} \frac{\mathbf{a} \mathbf{a}^\top}{\mathbf{a}^\top \mathbf{a}} = \frac{\mathbf{a} (\mathbf{a}^\top \mathbf{a}) \mathbf{a}^\top}{(\mathbf{a}^\top \mathbf{a})^2} = \frac{\mathbf{a} \mathbf{a}^\top}{\mathbf{a}^\top \mathbf{a}} = P, \quad (6.35)$$

中间一步把标量 $\mathbf{a}^\top \mathbf{a}$ 约掉了。几何上这很自然： $\mathbf{p}$ 已经在直线上，再投影一次不会动。第二条：

$$P^\top = P, \quad (6.36)$$

因为 $(\mathbf{a} \mathbf{a}^\top)^\top = \mathbf{a} \mathbf{a}^\top$ ，转置不改变分子，分母又是标量。正交投影的矩阵一定对称。

与 P 搭配的还有 $I - P$ 。它作用在 $\mathbf{b}$ 上给出

$$(I - P) \mathbf{b} = \mathbf{b} - \mathbf{p} = \mathbf{e}, \quad (6.37)$$

即把 $\mathbf{b}$ 投影到与 $\mathbf{a}$ 垂直的方向上。 P 与 $I - P$ 正好把向量拆成“沿直线”与“垂直直线”两部分。

6.3 投影到列空间

现在把直线换成一般的列空间。设 $A \in \mathbb{R}^{m \times n}$ ，并且它的 n 个列向量线性无关——这个条件后面马上会用到，不能丢。给定 $\mathbf{b} \in \mathbb{R}^m$ ，要在 $C(A)$ 中找离 $\mathbf{b}$ 最近的向量，即 $\mathbf{b}$ 在 $C(A)$ 上的投影。

列空间里的向量都是列向量的线性组合，也就是某个 $A\hat{\mathbf{x}}$ ，所以投影一定可以写成

$$\mathbf{p} = A\hat{\mathbf{x}}. \quad (6.38)$$

未知量从标量 $\hat{x}$ 变成了向量 $\hat{\mathbf{x}}$ ，但投影的条件不变：误差

$$\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}} \quad (6.39)$$

必须垂直于整个列空间。一个向量垂直于列空间，当且仅当它垂直于 A 的每一列——与每列做点积都为零，与它们任意线性组合的点积自然也为零。逐列写出来：

$$\mathbf{a}_1^\top \mathbf{e} = 0, \quad \mathbf{a}_2^\top \mathbf{e} = 0, \quad \dots, \quad \mathbf{a}_n^\top \mathbf{e} = 0, \quad (6.40)$$

其中 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 是 A 的各列。把这 n 个等式叠在一起，恰好是

$$A^\top \mathbf{e} = \mathbf{0}. \quad (6.41)$$

代入 $\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}}$ ：

$$A^\top (\mathbf{b} - A\hat{\mathbf{x}}) = \mathbf{0}. \quad (6.42)$$

分配开再移项：

$$\boxed{A^\top A \hat{\mathbf{x}} = A^\top \mathbf{b}}. \quad (6.43)$$

这组方程称为**正规方程**。直线情形是它的特例：当 A 只有一列 $\mathbf{a}$ 时， $A^\top A = \mathbf{a}^\top \mathbf{a}$ ， $A^\top \mathbf{b} = \mathbf{a}^\top \mathbf{b}$ ，正规方程就退化成上一节的 $\hat{x} \mathbf{a}^\top \mathbf{a} = \mathbf{a}^\top \mathbf{b}$ 。

要从正规方程解出 $\hat{\mathbf{x}}$ ，需要 $A^\top A$ 可逆。“列向量线性无关”这个条件正是在这里派上用场。我们验证 $A^\top A$ 的零空间只有零向量：若

$$A^\top A \mathbf{x} = \mathbf{0}, \quad (6.44)$$

两边左乘 $\mathbf{x}^\top$ ，得

$$\mathbf{x}^\top A^\top A \mathbf{x} = 0. \quad (6.45)$$

左边结合一下，正好是

$$(\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{x}) = \|\mathbf{A}\mathbf{x}\|^2. \quad (6.46)$$

长度为零的向量只有零向量，所以 $\mathbf{A}\mathbf{x} = \mathbf{0}$ 。而列向量线性无关时， $\mathbf{A}\mathbf{x} = \mathbf{0}$ 只有解 $\mathbf{x} = \mathbf{0}$ 。于是 $A^\top A$ 这个 $n \times n$ 方阵的零空间只有零向量，它可逆。

因此可以把 $\hat{\mathbf{x}}$ 解出来：

$$\boxed{\hat{\mathbf{x}} = (A^\top A)^{-1} A^\top \mathbf{b}}. \quad (6.47)$$

投影向量是

$$\mathbf{p} = A\hat{\mathbf{x}} = A(A^T A)^{-1} A^T \mathbf{b}, \quad (6.48)$$

所以投影到 $C(A)$ 的投影矩阵为

$$\boxed{P = A(A^T A)^{-1} A^T}. \quad (6.49)$$

这里有个常见错误要避开：不能把括号拆开写成 $AA^{-1}(A^T)^{-1}A^T = I$ ，因为 A 一般不是方阵，根本没有逆。

$P^2 = P$ 与 $P^T = P$ 仍然成立。以 P^2 为例：

$$P^2 = A(A^T A)^{-1} A^T A(A^T A)^{-1} A^T = A(A^T A)^{-1} (A^T A) (A^T A)^{-1} A^T, \quad (6.50)$$

中间的 $(A^T A)^{-1}(A^T A)$ 是单位矩阵，约去后即得 $P^2 = P$ 。对称性同样直接展开验证即可。

误差落在哪？ $\mathbf{e} = \mathbf{b} - \mathbf{p}$ 满足 $A^T \mathbf{e} = \mathbf{0}$ ，也就是说

$$\mathbf{e} = \mathbf{b} - \mathbf{p} \in N(A^T). \quad (6.51)$$

这与第一节完全一致： $\mathbf{b}$ 被拆成了列空间里的 $\mathbf{p}$ 和左零空间里的 $\mathbf{e}$ ，两者正交。

6.4 最小二乘

实际中最常遇到的是方程个数比未知数多的情形： $A \in \mathbb{R}^{m \times n}$ ， $m > n$ 。这时

$$A\mathbf{x} = \mathbf{b} \quad (6.52)$$

通常没有精确解，因为 $C(A)$ 只是 $\mathbb{R}^m$ 中一个 n 维子空间， $\mathbf{b}$ 多半不在里面。

无解不等于没办法。 $A\mathbf{x} - \mathbf{b}$ 的第 i 个分量，就是第 i 个方程“差多少”。这些误差有正有负，直接相加会互相抵消，所以改为最小化误差的平方和：

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|^2. \quad (6.53)$$

让误差平方和最小的 $\hat{\mathbf{x}}$ 称为**最小二乘解**。

几何上这个问题已经解决了： $\|A\mathbf{x} - \mathbf{b}\|$ 是 $\mathbf{b}$ 到列空间中向量 $A\mathbf{x}$ 的距离，距离最近时 $A\hat{\mathbf{x}}$ 正是 $\mathbf{b}$ 在 $C(A)$ 上的投影。于是最佳误差

$$\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}} \quad (6.54)$$

满足 $A^T \mathbf{e} = \mathbf{0}$ ，再次得到正规方程

$$A^T A \hat{\mathbf{x}} = A^T \mathbf{b}. \quad (6.55)$$

纯代数也能看到同一个结论。固定 $\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}}$ ，对任意 $\mathbf{x}$ 把误差向量拆开：

$$A\mathbf{x} - \mathbf{b} = A\mathbf{x} - A\hat{\mathbf{x}} + A\hat{\mathbf{x}} - \mathbf{b} = A(\mathbf{x} - \hat{\mathbf{x}}) - \mathbf{e}. \quad (6.56)$$

前一项 $A(\mathbf{x} - \hat{\mathbf{x}})$ 属于 $C(A)$, $\mathbf{e}$ 属于 $N(A^\top)$, 两者正交。正交向量之和的长度平方可以逐项展开, 交叉项都是零:

$$\|A\mathbf{x} - \mathbf{b}\|^2 = \|A(\mathbf{x} - \hat{\mathbf{x}})\|^2 + \|\mathbf{e}\|^2 \geq \|\mathbf{e}\|^2. \quad (6.57)$$

等号成立当且仅当 $A(\mathbf{x} - \hat{\mathbf{x}}) = \mathbf{0}$; 列向量线性无关时, 这等价于 $\mathbf{x} = \hat{\mathbf{x}}$ 。所以正规方程的解确实唯一地给出最小值。

也可以把目标函数直接展开 (这一步以后会有用):

$$\|A\mathbf{x} - \mathbf{b}\|^2 = (A\mathbf{x} - \mathbf{b})^\top (A\mathbf{x} - \mathbf{b}) = \mathbf{x}^\top A^\top A\mathbf{x} - 2\mathbf{x}^\top A^\top \mathbf{b} + \mathbf{b}^\top \mathbf{b}. \quad (6.58)$$

展开时注意 $\mathbf{b}^\top A\mathbf{x}$ 与 $\mathbf{x}^\top A^\top \mathbf{b}$ 都是标量, 且互为转置, 所以相等, 合并成 $-2\mathbf{x}^\top A^\top \mathbf{b}$ 。

最经典的应用是直线拟合。给定 m 个数据点 (t_i, b_i) , 想用一条直线

$$b = C + Dt \quad (6.59)$$

尽量经过它们。把每个点代入, 得到 m 个方程

$$C + Dt_i = b_i, \quad i = 1, 2, \dots, m, \quad (6.60)$$

写成矩阵形式 $A\mathbf{x} = \mathbf{b}$, 其中

$$A = \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} C \\ D \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}. \quad (6.61)$$

只要数据点不恰好共线, 这 m 个方程就没有公共解 (C, D) , 而正规方程给出平方误差最小的那条直线。

完整算一个例子。取三个数据点

$$(0, 1), \quad (1, 5), \quad (2, 3). \quad (6.62)$$

先确认它们不共线: 前两个点确定的直线是 $b = 1 + 4t$, 它在 $t = 2$ 处给出 9, 与第三个点的纵坐标 3 不符。于是转向最小二乘。三个方程是

$$C = 1, \quad C + D = 5, \quad C + 2D = 3, \quad (6.63)$$

对应

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 5 \\ 3 \end{bmatrix}. \quad (6.64)$$

计算 $A^\top A$: 用 $A^\top$ 的第一行 $(1, 1, 1)$ 与第二行 $(0, 1, 2)$, 分别与 A 的两列做点积,

$$A^\top A = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 1+1+1 & 0+1+2 \\ 0+1+2 & 0+1+4 \end{bmatrix} = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}. \quad (6.65)$$

再算 $A^T \mathbf{b}$:

$$A^T \mathbf{b} = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 5 \\ 3 \end{bmatrix} = \begin{bmatrix} 1+5+3 \\ 0+5+6 \end{bmatrix} = \begin{bmatrix} 9 \\ 11 \end{bmatrix}. \quad (6.66)$$

正规方程是

$$\begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} 9 \\ 11 \end{bmatrix}, \quad \text{即} \quad 3C + 3D = 9, \quad 3C + 5D = 11. \quad (6.67)$$

第一式除以 3 得 $C + D = 3$; 第二式减去第一式得 $2D = 2$ 。于是

$$D = 1, \quad C = 2, \quad (6.68)$$

最佳直线是 $b = 2 + t$ 。

看看这条直线在三个数据点处的表现。预测值是

$$\mathbf{p} = A\hat{\mathbf{x}} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix}, \quad (6.69)$$

误差是

$$\mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix} 1 \\ 5 \\ 3 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \\ -1 \end{bmatrix}. \quad (6.70)$$

检验 $\mathbf{e}$ 是否垂直于 A 的两列:

$$(1, 1, 1) \cdot \mathbf{e} = -1 + 2 - 1 = 0, \quad (0, 1, 2) \cdot \mathbf{e} = 0 + 2 - 2 = 0. \quad (6.71)$$

都为零, 即 $\mathbf{e} \in N(A^T)$, 与理论一致。这条直线的平方误差是

$$\|\mathbf{e}\|^2 = (-1)^2 + 2^2 + (-1)^2 = 6. \quad (6.72)$$

回头看, 这个例子做的就是一件事实: 把 $\mathbf{b} = (1, 5, 3)^T$ 投影到 A 的列空间, $\mathbf{p}$ 是投影, $\mathbf{e}$ 是落在左零空间里的那一部分。

6.5 正交归一基与正交矩阵

如果一组向量两两正交, 并且长度都是 1, 很多公式会一下子变简单。满足

$$\mathbf{q}_i^T \mathbf{q}_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j \end{cases} \quad (6.73)$$

的向量组 $\mathbf{q}_1, \dots, \mathbf{q}_n$ 称为正交归一的: $i \neq j$ 那一行说两两正交, $i = j$ 那一行说每个向量与自身的点积为 1, 即长度都是 1。

把它们并排成矩阵

$$Q = \begin{bmatrix} \mathbf{q}_1 & \cdots & \mathbf{q}_n \end{bmatrix}, \quad (6.74)$$

计算 $Q^T Q$ 的第 (i, j) 个元素：它是 Q^T 的第 i 行（即 $\mathbf{q}_i^T$ ）与 Q 的第 j 列（即 $\mathbf{q}_j$ ）的点积 $\mathbf{q}_i^T \mathbf{q}_j$ 。由正交归一的定义，这个矩阵对角线上全是 1，其余全是 0：

$$\boxed{Q^T Q = I.} \quad (6.75)$$

当 Q 是方阵时，这 n 个列向量构成 $\mathbb{R}^n$ 的一组正交归一基。它们必然线性无关：若 $c_1 \mathbf{q}_1 + \cdots + c_n \mathbf{q}_n = \mathbf{0}$ ，两边与 $\mathbf{q}_j$ 做点积，左边只剩 c_j ，所以每个 $c_j = 0$ 。此时 $Q^T Q = I$ 意味着 Q^T 就是 Q 的逆，并且

$$Q Q^T = I, \quad \boxed{Q^{-1} = Q^T.} \quad (6.76)$$

满足 $Q^{-1} = Q^T$ 的方阵称为**正交矩阵**。求逆变成一次转置，这是正交矩阵最省事的地方。平面上的旋转矩阵就是一个例子：

$$Q = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}, \quad Q^T Q = \begin{bmatrix} \cos^2 \theta + \sin^2 \theta & 0 \\ 0 & \cos^2 \theta + \sin^2 \theta \end{bmatrix} = I. \quad (6.77)$$

正交归一列让投影公式大幅简化。把一般投影公式 (6.48) 里的 A 换成 Q ，正规方程 $Q^T Q \hat{\mathbf{x}} = Q^T \mathbf{b}$ 的系数矩阵直接就是单位矩阵，于是

$$\hat{\mathbf{x}} = Q^T \mathbf{b}, \quad \mathbf{p} = Q \hat{\mathbf{x}} = Q Q^T \mathbf{b}, \quad P = Q Q^T. \quad (6.78)$$

完全不需要求逆。而且投影系数 $\hat{x}_i = \mathbf{q}_i^T \mathbf{b}$ 各自独立：第 i 个系数只与第 i 个基向量有关。这就是后面的计算都想办法把基变成正交归一基的原因。

6.6 Gram-Schmidt 正交化与 QR 分解

手头一般不会正好有正交归一基。Gram-Schmidt 正交化做的事是：从一组线性无关的向量

$$\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n \quad (6.79)$$

出发，逐个减去“已经在前面各方向上的部分”，造出与原来张成同一子空间的正交归一向量 $\mathbf{q}_1, \dots, \mathbf{q}_n$ 。

第一步没有前面的方向可减，直接归一化：

$$\mathbf{q}_1 = \frac{\mathbf{a}_1}{\|\mathbf{a}_1\|}. \quad (6.80)$$

第二步，从 $\mathbf{a}_2$ 中减去它在 $\mathbf{q}_1$ 方向上的投影。因为 $\|\mathbf{q}_1\| = 1$ ，投影公式 (6.25) 简化成 $(\mathbf{q}_1^T \mathbf{a}_2) \mathbf{q}_1$ ，于是

$$\mathbf{u}_2 = \mathbf{a}_2 - (\mathbf{q}_1^T \mathbf{a}_2) \mathbf{q}_1, \quad \mathbf{q}_2 = \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|}. \quad (6.81)$$

验证 $\mathbf{u}_2$ 确实与 $\mathbf{q}_1$ 正交:

$$\mathbf{q}_1^\top \mathbf{u}_2 = \mathbf{q}_1^\top \mathbf{a}_2 - (\mathbf{q}_1^\top \mathbf{a}_2) \mathbf{q}_1^\top \mathbf{q}_1 = \mathbf{q}_1^\top \mathbf{a}_2 - \mathbf{q}_1^\top \mathbf{a}_2 = 0, \quad (6.82)$$

其中用到 $\mathbf{q}_1^\top \mathbf{q}_1 = 1$ 。

一般地, 第 k 步把 $\mathbf{a}_k$ 在前面 $k-1$ 个方向上的投影全部减掉:

$$\mathbf{u}_k = \mathbf{a}_k - \sum_{j=1}^{k-1} (\mathbf{q}_j^\top \mathbf{a}_k) \mathbf{q}_j, \quad (6.83)$$

再归一化:

$$\mathbf{q}_k = \frac{\mathbf{u}_k}{\|\mathbf{u}_k\|}. \quad (6.84)$$

$\mathbf{u}_k$ 与之前的每个 $\mathbf{q}_j$ ($j < k$) 都正交:

$$\mathbf{q}_j^\top \mathbf{u}_k = \mathbf{q}_j^\top \mathbf{a}_k - (\mathbf{q}_j^\top \mathbf{a}_k) \mathbf{q}_j^\top \mathbf{q}_j = 0, \quad (6.85)$$

因为和式中除第 j 项外的 $\mathbf{q}$ 都与 $\mathbf{q}_j$ 正交, 点积后只有第 j 项留下来。 $\mathbf{u}_k$ 也不会是零向量: 它是 $\mathbf{a}_k$ 减去前 $k-1$ 个向量张成空间中的某个向量, 而 $\mathbf{a}_1, \dots, \mathbf{a}_k$ 线性无关, $\mathbf{a}_k$ 不在这个空间里, 减完不可能为零, 归一化永远不会除以零。这样得到的 $\mathbf{q}_1, \dots, \mathbf{q}_n$ 两两正交归一, 并且对每个 k , 前 k 个 $\mathbf{q}$ 与前 k 个 $\mathbf{a}$ 张成同一个子空间。

用两个具体的三维向量完整算一遍。取

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}. \quad (6.86)$$

第一步, 算 $\mathbf{a}_1$ 的长度:

$$\|\mathbf{a}_1\|^2 = 1^2 + 2^2 + 2^2 = 9, \quad \|\mathbf{a}_1\| = 3, \quad \mathbf{q}_1 = \frac{1}{3} \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}. \quad (6.87)$$

第二步, 先算投影系数:

$$\mathbf{q}_1^\top \mathbf{a}_2 = \frac{1}{3}(1 \cdot 1 + 2 \cdot 1 + 2 \cdot 0) = \frac{3}{3} = 1. \quad (6.88)$$

从 $\mathbf{a}_2$ 中减掉这份投影:

$$\mathbf{u}_2 = \mathbf{a}_2 - 1 \cdot \mathbf{q}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 1/3 \\ 2/3 \\ 2/3 \end{bmatrix} = \begin{bmatrix} 2/3 \\ 1/3 \\ -2/3 \end{bmatrix}. \quad (6.89)$$

再算 $\mathbf{u}_2$ 的长度:

$$\|\mathbf{u}_2\|^2 = \frac{4}{9} + \frac{1}{9} + \frac{4}{9} = 1, \quad \|\mathbf{u}_2\| = 1, \quad \mathbf{q}_2 = \mathbf{u}_2 = \begin{bmatrix} 2/3 \\ 1/3 \\ -2/3 \end{bmatrix}. \quad (6.90)$$

最后检验正交性:

$$\mathbf{q}_1^\top \mathbf{q}_2 = \frac{1}{3} \cdot \frac{2}{3} + \frac{2}{3} \cdot \frac{1}{3} + \frac{2}{3} \cdot \left(-\frac{2}{3}\right) = \frac{2+2-4}{9} = 0. \quad (6.91)$$

两个向量长度都是 1, 又互相正交, 正交归一化完成。

Gram-Schmidt 还顺手给出一种矩阵分解。把原向量与新向量分别作为矩阵的列:

$$A = [\mathbf{a}_1 \ \cdots \ \mathbf{a}_n], \quad Q = [\mathbf{q}_1 \ \cdots \ \mathbf{q}_n]. \quad (6.92)$$

把上面的过程反过来看: $\mathbf{a}_1 = \|\mathbf{a}_1\| \mathbf{q}_1$ 只用 $\mathbf{q}_1$ 表示, $\mathbf{a}_2 = (\mathbf{q}_1^\top \mathbf{a}_2) \mathbf{q}_1 + \|\mathbf{u}_2\| \mathbf{q}_2$ 只用 $\mathbf{q}_1, \mathbf{q}_2$ 表示, 一般地 $\mathbf{a}_k$ 只用前 k 个 $\mathbf{q}$ 表示。把这些系数收进一个上三角矩阵 R , 就有

$$\boxed{A = QR.} \quad (6.93)$$

左乘 $Q^\top$, 利用 $Q^\top Q = I$, 得

$$\boxed{R = Q^\top A.} \quad (6.94)$$

这就是 QR 分解。

用刚才的例子验证。 R 的元素是各 $\mathbf{q}$ 与各 $\mathbf{a}$ 的点积:

$$R = Q^\top A = \begin{bmatrix} \mathbf{q}_1^\top \mathbf{a}_1 & \mathbf{q}_1^\top \mathbf{a}_2 \\ \mathbf{q}_2^\top \mathbf{a}_1 & \mathbf{q}_2^\top \mathbf{a}_2 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 0 & 1 \end{bmatrix}, \quad (6.95)$$

其中 $\mathbf{q}_1^\top \mathbf{a}_1 = \|\mathbf{a}_1\| = 3$, $\mathbf{q}_2^\top \mathbf{a}_1 = 0$ 正是刚验证过的正交性, $\mathbf{q}_2^\top \mathbf{a}_2 = \frac{2}{3} + \frac{1}{3} + 0 = 1$ 。乘回去检查: 第一列 $3\mathbf{q}_1 = \mathbf{a}_1$; 第二列 $1 \cdot \mathbf{q}_1 + 1 \cdot \mathbf{q}_2 = (1/3 + 2/3, 2/3 + 1/3, 2/3 - 2/3)^\top = (1, 1, 0)^\top = \mathbf{a}_2$ 。 $A = QR$ 确实成立。

QR 分解在最小二乘中特别好用。设 $A = QR$, 则

$$A^\top A = (QR)^\top (QR) = R^\top Q^\top QR = R^\top R, \quad (6.96)$$

中间用到了 $Q^\top Q = I$ 。正规方程

$$A^\top A \hat{\mathbf{x}} = A^\top \mathbf{b} \quad (6.97)$$

于是化为

$$R^\top R \hat{\mathbf{x}} = R^\top Q^\top \mathbf{b}. \quad (6.98)$$

R 的对角元是各步归一化之前的长度 $\|\mathbf{u}_k\|$, 全都大于零, 所以 R 可逆, $R^\top$ 也可逆。两边左乘 $(R^\top)^{-1}$, 得到

$$\boxed{R \hat{\mathbf{x}} = Q^\top \mathbf{b}.} \quad (6.99)$$

右边只是几次点积, 左边是上三角方程组, 从最后一个未知数开始逐个回代即可。最小二乘就这样化成了一次回代。

7 特征值、对角化与正定矩阵

前面几章的核心问题是线性方程组 $A\mathbf{x} = \mathbf{b}$: 已知矩阵 A 和输出 $\mathbf{b}$, 反推输入 $\mathbf{x}$ 。这一章换一个角度。把 A 乘在一个向量 $\mathbf{x}$ 上, 得到的 $A\mathbf{x}$ 通常会转向别的方向; 但对某些特殊向量, $A\mathbf{x}$ 仍停留在原来的方向上, 只是被拉长或缩短。这些特殊方向就是本章的主角。沿着它们看, 矩阵的作用退化成最简单的“乘上一个数”, 矩阵的高次幂、微分方程、二次型的正负这些原本复杂的问题, 都会因此变得清楚。

7.1 特征值与特征向量

设 A 是 $n \times n$ 方阵。若非零向量 $\mathbf{x} \neq \mathbf{0}$ 满足

$$A\mathbf{x} = \lambda\mathbf{x}, \quad (7.1)$$

就称 $\mathbf{x}$ 是 A 的一个**特征向量**, 标量 λ 称为对应的**特征值**。这个等式的意思是: A 作用在 $\mathbf{x}$ 上, 结果仍沿着 $\mathbf{x}$ 的方向, 只是长度被乘上了 λ 。

这里必须排除零向量。 $\mathbf{x} = \mathbf{0}$ 时等式 $A\mathbf{0} = \lambda\mathbf{0}$ 对任何 λ 都成立, 它不携带任何方向信息。特征向量讨论的是“方向不变”, 所以定义里一开始就要求 $\mathbf{x} \neq \mathbf{0}$ 。

怎样把特征值找出来? 把右边移到左边, 并注意 $\lambda\mathbf{x} = \lambda I\mathbf{x}$, 得

$$(A - \lambda I)\mathbf{x} = \mathbf{0}. \quad (7.2)$$

我们要求这个齐次方程存在非零解。第3章讲过, 这类方程有没有非零解, 与系数矩阵是否可逆直接相连: 要有非零解, $A - \lambda I$ 必须不可逆, 也就是行列式为零:

$$\boxed{\det(A - \lambda I) = 0.} \quad (7.3)$$

这是关于 λ 的多项式方程, 称为**特征方程**, 左边的多项式称为**特征多项式**。于是整个计算分两步: 先解特征方程得到所有特征值, 再对每个特征值解齐次方程 $(A - \lambda I)\mathbf{x} = \mathbf{0}$, 求出对应的特征向量。

拿一个 2×2 矩阵完整算一遍。设

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}. \quad (7.4)$$

第一步, 写出特征多项式。先算

$$A - \lambda I = \begin{bmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix}, \quad (7.5)$$

于是

$$\det(A - \lambda I) = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3. \quad (7.6)$$

第二步, 解特征方程

$$\lambda^2 - 4\lambda + 3 = 0. \quad (7.7)$$

左边因式分解成 $(\lambda - 1)(\lambda - 3)$, 所以两个特征值为

$$\lambda_1 = 1, \quad \lambda_2 = 3. \quad (7.8)$$

第三步, 对每个特征值分别解 $(A - \lambda I)\mathbf{x} = \mathbf{0}$ 。

对 $\lambda_1 = 1$, 系数矩阵是

$$A - I = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0}. \quad (7.9)$$

两行给出的是同一个方程 $x_1 + x_2 = 0$, 即 $x_2 = -x_1$ 。取 $x_1 = 1$, 得特征向量

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \quad (7.10)$$

对 $\lambda_2 = 3$, 系数矩阵是

$$A - 3I = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0}. \quad (7.11)$$

两行都是 $-x_1 + x_2 = 0$, 即 $x_2 = x_1$ 。取 $x_1 = 1$, 得

$$\mathbf{x}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}. \quad (7.12)$$

最后代回定义验证:

$$A\mathbf{x}_1 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 1 \cdot \mathbf{x}_1, \quad A\mathbf{x}_2 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3\mathbf{x}_2. \quad (7.13)$$

两个等式都成立, 计算无误。

注意特征向量并不唯一: $\mathbf{x}_1$ 的任何非零倍数仍满足 $A\mathbf{x} = 1 \cdot \mathbf{x}$, 仍是属于 $\lambda_1 = 1$ 的特征向量。属于同一特征值的所有特征向量, 再添上零向量, 构成一个子空间, 称为该特征值的**特征空间**。上例中两个特征空间分别是沿 $(1, -1)$ 与沿 $(1, 1)$ 的两条直线。

有几个基本事实最好一并记住。若 A 是 $n \times n$ 方阵, 把重根按次数计入, 特征方程一共有 n 个复数根 $\lambda_1, \dots, \lambda_n$ 。它们与矩阵本身有两个简洁的联系:

$$\lambda_1 + \dots + \lambda_n = \text{tr}(A), \quad (7.14)$$

$$\lambda_1 \lambda_2 \cdots \lambda_n = \det(A). \quad (7.15)$$

其中

$$\text{tr}(A) = a_{11} + \dots + a_{nn} \quad (7.16)$$

是对角线元素之和, 称为矩阵的**迹**。用刚才的例子核对: $1 + 3 = 4$, 等于迹 $2 + 2$; $1 \times 3 = 3$, 等于行列式 $4 - 1$ 。每次算完特征值, 用这两条快速检验, 能挡掉大部分计算错误。

由第二条还能看出： $\lambda = 0$ 是特征值，当且仅当 $\det(A) = 0$ ，即 A 不可逆。这很直接—— $A\mathbf{x} = 0\mathbf{x} = \mathbf{0}$ 有非零解，说的就是 A 的零空间里存在非零向量。

如果 A 是三角矩阵， $A - \lambda I$ 仍是三角矩阵，行列式等于对角线元素的乘积：

$$\det(A - \lambda I) = (a_{11} - \lambda)(a_{22} - \lambda) \cdots (a_{nn} - \lambda). \quad (7.17)$$

所以三角矩阵的特征值就是对角线元素，直接读出来即可。

实矩阵的特征值不一定是实数。例如把平面旋转 90° 的矩阵

$$R = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \quad \det(R - \lambda I) = \lambda^2 + 1 = 0, \quad \lambda = \pm i. \quad (7.18)$$

几何上也合理：转过 90° 之后，没有任何实向量保持原来的方向，自然没有实特征值。特征值以共轭复数成对出现，在非对称矩阵中并不奇怪。

也有些矩阵的特征值能从几何意义直接读出。第 6 章的投影矩阵满足

$$P^2 = P. \quad (7.19)$$

若 $P\mathbf{x} = \lambda\mathbf{x}$ ，两边再作用一次 P ：

$$\lambda\mathbf{x} = P\mathbf{x} = P^2\mathbf{x} = P(\lambda\mathbf{x}) = \lambda P\mathbf{x} = \lambda^2\mathbf{x}. \quad (7.20)$$

由于 $\mathbf{x} \neq \mathbf{0}$ ，只能有 $\lambda^2 = \lambda$ ，所以特征值只能是

$$0 \quad \text{或} \quad 1. \quad (7.21)$$

几何含义同样清楚：列空间中的向量满足 $P\mathbf{x} = \mathbf{x}$ ，对应 $\lambda = 1$ ；零空间中的向量满足 $P\mathbf{x} = \mathbf{0}$ ，对应 $\lambda = 0$ 。

7.2 对角化

假设 A 有 n 个线性无关的特征向量

$$\mathbf{x}_1, \dots, \mathbf{x}_n, \quad (7.22)$$

分别对应特征值

$$\lambda_1, \dots, \lambda_n. \quad (7.23)$$

把这些特征向量按列排成矩阵

$$X = \begin{bmatrix} \mathbf{x}_1 & \cdots & \mathbf{x}_n \end{bmatrix}, \quad (7.24)$$

并把特征值放进对角矩阵

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n). \quad (7.25)$$

n 个特征方程 $A\mathbf{x}_i = \lambda_i\mathbf{x}_i$ 可以合并写成一个矩阵等式

$$AX = X\Lambda. \quad (7.26)$$

逐列看就明白了：左边 AX 的第 i 列是 $A\mathbf{x}_i$ ；右边 $X\Lambda$ 的第 i 列是 X 的第 i 列乘上 Λ 的第 i 个对角元素，即 $\lambda_i\mathbf{x}_i$ 。两边第 i 列相等，等式成立。

由于 X 的列向量线性无关， X 可逆。两边右乘 X^{-1} ，得

$$\boxed{A = X\Lambda X^{-1}}. \quad (7.27)$$

这称为矩阵的**对角化**： A 被分解成“特征向量矩阵 $\times$ 对角矩阵 $\times$ 特征向量矩阵的逆”。

先用上一节算好的例子验证一遍。那里

$$X = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}, \quad \Lambda = \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix}. \quad (7.28)$$

X 的行列式为 $1 - (-1) = 2 \neq 0$ ，可逆，且

$$X^{-1} = \frac{1}{2} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}. \quad (7.29)$$

逐步乘回去：

$$X\Lambda = \begin{bmatrix} 1 & 3 \\ -1 & 3 \end{bmatrix}, \quad X\Lambda X^{-1} = \frac{1}{2} \begin{bmatrix} 1 & 3 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} = A. \quad (7.30)$$

分解成立。

对角化的意义，用“换基”的语言来说最清楚。 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 线性无关，所以它们构成 $\mathbb{R}^n$ 的一组基——**特征向量基**。任何向量 $\mathbf{u}$ 都能唯一写成

$$\mathbf{u} = c_1\mathbf{x}_1 + \dots + c_n\mathbf{x}_n, \quad (7.31)$$

系数 $(c_1, \dots, c_n)$ 就是 $\mathbf{u}$ 在这组基下的坐标。让 A 作用上去：

$$A\mathbf{u} = c_1A\mathbf{x}_1 + \dots + c_nA\mathbf{x}_n = c_1\lambda_1\mathbf{x}_1 + \dots + c_n\lambda_n\mathbf{x}_n. \quad (7.32)$$

看坐标发生了什么：第 i 个坐标只是从 c_i 变成了 $\lambda_i c_i$ 。在原来的标准基下， A 把各个方向搅在一起；换到特征向量基之后，每个坐标各自乘上自己的特征值，彼此不再纠缠——这正是一个对角矩阵 Λ 所做的事。分解 $A = X\Lambda X^{-1}$ 对应三步： X^{-1} 把标准坐标换算成特征向量基坐标， Λ 在新坐标下逐坐标缩放， X 再把结果换回标准坐标。不同特征方向之间彼此解耦，每个方向只被乘上自己的特征值，这就是对角化的几何意义。

最直接的应用是矩阵幂。先平方：

$$A^2 = (X\Lambda X^{-1})(X\Lambda X^{-1}) = X\Lambda^2 X^{-1}, \quad (7.33)$$

中间的 $X^{-1}X = I$ 相互抵消。重复同样的抵消,

$$A^k = (X\Lambda X^{-1})^k = X\Lambda^k X^{-1}, \quad \Lambda^k = \text{diag}(\lambda_1^k, \dots, \lambda_n^k). \quad (7.34)$$

对角矩阵的 k 次幂只是把每个对角元素取 k 次幂, 于是 A^k 的计算被化成 n 个数的乘方。对我们的例子,

$$A^k = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 3^k \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1+3^k & -1+3^k \\ -1+3^k & 1+3^k \end{bmatrix}. \quad (7.35)$$

代入 $k=1$ 正好还原出 A 。

矩阵幂回答了一类离散系统的长期行为。若初始向量

$$\mathbf{u}_0 = c_1 \mathbf{x}_1 + \dots + c_n \mathbf{x}_n, \quad (7.36)$$

则递推系统

$$\mathbf{u}_{k+1} = A\mathbf{u}_k \quad (7.37)$$

的解为

$$\mathbf{u}_k = A^k \mathbf{u}_0 = \sum_{i=1}^n c_i \lambda_i^k \mathbf{x}_i. \quad (7.38)$$

每迭代一次, 第 i 个特征方向上的分量就乘一次 λ_i 。因此长期行为由特征值的绝对值控制。若所有

$$|\lambda_i| < 1, \quad (7.39)$$

则每个分量都衰减到零, 从而

$$A^k \rightarrow 0; \quad (7.40)$$

只要有一个 $|\lambda_i| > 1$, 对应方向上的分量就会被不断放大。

并非所有矩阵都能对角化。关键不在于“有 n 个特征值”——计入重数后总有 n 个——而在于有没有 n 个线性无关的特征向量。若 n 个特征值互不相同, 对应的特征向量必然线性无关, 对角化没有障碍。问题出在重复特征值上: 它未必能提供与重复次数一样多的线性无关特征向量。特征值作为特征多项式的根出现的次数称为**代数重数**, 对应特征空间的维数——它实际能提供的线性无关特征向量的个数——称为**几何重数**。矩阵可对角化, 当且仅当每个特征值的几何重数都达到它的代数重数, 合起来恰好凑出 n 个线性无关的特征向量。

若

$$A = BCB^{-1}, \quad (7.41)$$

则称 A 与 C 相似。相似矩阵有相同的特征值: 设 $C\mathbf{x} = \lambda\mathbf{x}$, 令 $\mathbf{y} = B\mathbf{x}$, 则

$$A\mathbf{y} = BCB^{-1}B\mathbf{x} = BC\mathbf{x} = B(\lambda\mathbf{x}) = \lambda B\mathbf{x} = \lambda\mathbf{y}, \quad (7.42)$$

即 λ 也是 A 的特征值, 特征向量由 $\mathbf{x}$ 变成 $B\mathbf{x}$ 。相似矩阵表示同一个线性变换在不同基下的矩阵, 特征值是变换本身的属性, 换基不会改变它。对角化正是要找一个与 A 相似的对角矩阵 Λ ——在特征向量基下, 这个变换呈现出最简单的样子。

7.3 微分方程与矩阵指数

递推 $\mathbf{u}_{k+1} = A\mathbf{u}_k$ 描述离散时间的变化，它的连续时间版本是微分方程组

$$\frac{d\mathbf{u}}{dt} = A\mathbf{u}, \quad (7.43)$$

其中 $\mathbf{u}(t)$ 是随时间演化的向量。一维情形 $du/dt = \lambda u$ 的解是 $u(t) = e^{\lambda t}u(0)$ ，这提示我们尝试指数形式的解。

设 $A\mathbf{x} = \lambda\mathbf{x}$ ，取

$$\mathbf{u}(t) = e^{\lambda t}\mathbf{x}. \quad (7.44)$$

逐项验证它满足方程。左边对 t 求导：

$$\frac{d\mathbf{u}}{dt} = \lambda e^{\lambda t}\mathbf{x}; \quad (7.45)$$

右边用特征方程：

$$A\mathbf{u}(t) = e^{\lambda t}A\mathbf{x} = \lambda e^{\lambda t}\mathbf{x}. \quad (7.46)$$

两边相等。因此每个特征向量都给出一个独立的指数解，称为一个**模式**。一般解是这些模式的叠加：若

$$\mathbf{u}(0) = c_1\mathbf{x}_1 + \cdots + c_n\mathbf{x}_n, \quad (7.47)$$

则

$$\mathbf{u}(t) = c_1 e^{\lambda_1 t}\mathbf{x}_1 + \cdots + c_n e^{\lambda_n t}\mathbf{x}_n. \quad (7.48)$$

这与离散情形完全平行，只是 λ_i^k 换成了 $e^{\lambda_i t}$ 。

若 $A = X\Lambda X^{-1}$ ，这套解可以打包成一个矩阵。模仿 e^x 的泰勒级数，定义**矩阵指数**

$$e^{At} = I + At + \frac{(At)^2}{2!} + \cdots. \quad (7.49)$$

把 $(At)^k = A^k t^k = X(\Lambda t)^k X^{-1}$ 代入级数的每一项：

$$e^{At} = XX^{-1} + X(\Lambda t)X^{-1} + X\frac{(\Lambda t)^2}{2!}X^{-1} + \cdots. \quad (7.50)$$

每一项左边提出 X 、右边提出 X^{-1} ，中间恰好又拼成指数级数，于是

$$\boxed{e^{At} = Xe^{\Lambda t}X^{-1}}, \quad (7.51)$$

其中

$$e^{\Lambda t} = \text{diag}(e^{\lambda_1 t}, \dots, e^{\lambda_n t}). \quad (7.52)$$

对角矩阵取指数，只需对每个对角元素分别取指数。初值问题的解由此写成

$$\mathbf{u}(t) = e^{At}\mathbf{u}(0). \quad (7.53)$$

稳定性同样由特征值决定。若所有特征值都满足

$$\text{Re}(\lambda_i) < 0, \quad (7.54)$$

则每个模式 $e^{\lambda_i t}$ 都衰减，因而

$$e^{At} \rightarrow 0, \quad t \rightarrow \infty. \quad (7.55)$$

这里要看实部，是因为特征值可能是复数。本章一直在用的矩阵特征值为 1 与 3，模式 e^t 与 e^{3t} 都在增长，对应的系统不稳定。离散与连续两个判据放在一起很整齐：离散系统要 $|\lambda_i| < 1$ ，连续系统要 $\text{Re}(\lambda_i) < 0$ 。

7.4 对称矩阵与谱定理

对称矩阵

$$S^T = S \quad (7.56)$$

在特征值理论中具有特别整齐的结构：

1. 所有特征值都为实数；
2. 可以选取一组正交归一的特征向量作为整个 $\mathbb{R}^n$ 的基。

第二条中“正交归一”的意思是：任意两个不同的特征向量点积为零，且每个特征向量的长度为一。

把这样一组单位特征向量按列排成矩阵

$$Q = \begin{bmatrix} \mathbf{q}_1 & \cdots & \mathbf{q}_n \end{bmatrix}. \quad (7.57)$$

列与列正交、长度都为一，用矩阵乘法写出来恰好是

$$Q^T Q = Q Q^T = I, \quad (7.58)$$

这样的矩阵称为**正交矩阵**，它的逆就是转置： $Q^{-1} = Q^T$ 。令

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n), \quad (7.59)$$

一般对角化公式 (7.27) 中的 X^{-1} 于是简化成 Q^T ：

$$\boxed{S = Q \Lambda Q^T}. \quad (7.60)$$

这就是实对称矩阵的**谱定理**，“谱”指特征值的全体。

与一般的

$$A = X \Lambda X^{-1} \quad (7.61)$$

相比，对称矩阵把 X^{-1} 简化成了 Q^T 。从几何上可以把

$$S = Q \Lambda Q^T \quad (7.62)$$

读成三步：先用 Q^T 旋转到特征向量坐标系，再沿各个特征方向按 λ_i 缩放，最后用 Q 旋转回来。旋转不改变长度与角度，所以对称矩阵的全部作用，本质上就是沿一组互相垂直的方向各自缩放。

为什么不同特征值对应的特征向量必然正交？设

$$S\mathbf{x} = \lambda\mathbf{x}, \quad S\mathbf{y} = \mu\mathbf{y}, \quad \lambda \neq \mu. \quad (7.63)$$

用两种方式计算 $\mathbf{y}^T S\mathbf{x}$ 。先把 $S\mathbf{x} = \lambda\mathbf{x}$ 代入：

$$\mathbf{y}^T S\mathbf{x} = \lambda \mathbf{y}^T \mathbf{x}. \quad (7.64)$$

再利用对称性把 S 挪到 $\mathbf{y}$ 上：由 $\mathbf{y}^T S = (S\mathbf{y})^T = (\mu\mathbf{y})^T = \mu\mathbf{y}^T$ ，得

$$\mathbf{y}^T S\mathbf{x} = \mu \mathbf{y}^T \mathbf{x}. \quad (7.65)$$

两式相减，

$$(\lambda - \mu) \mathbf{y}^T \mathbf{x} = 0. \quad (7.66)$$

因为 $\lambda \neq \mu$ ，只能有 $\mathbf{y}^T \mathbf{x} = 0$ ，即 $\mathbf{x}$ 与 $\mathbf{y}$ 正交。

即使某个特征值重复出现，也可以在它的特征空间内部选一组正交归一基。因此任何实对称矩阵都一定可以正交对角化。

本章的例子正好是对称矩阵，可以直接看到这一切。两个特征向量 $(1, -1)$ 与 $(1, 1)$ 的点积为 $1 - 1 = 0$ ，天然正交；各除以长度 $\sqrt{2}$ 归一化，得

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad Q = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}. \quad (7.67)$$

谱定理给出分解

$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} = Q \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix} Q^T. \quad (7.68)$$

把右边乘开，可以验证它确实等于左边的矩阵。

7.5 正定矩阵

在对称矩阵中，若所有特征值都为正数，则称矩阵 S **正定**。正定性有几种彼此等价的重要判据：

S 对称且所有特征值 $\lambda_i > 0$ $\iff S$ 的所有主元都为正 $\iff S$ 的所有顺序左上主子式都为正 $\iff \mathbf{x}^T S \mathbf{x} > 0 \quad (\mathbf{x} \neq \mathbf{0}).$

(7.69)

主元是消元后留在对角线上的那些数（第 4 章）；第 k 个**顺序左上主子式**是左上角 $k \times k$ 子矩阵的行列式。最后一条称为**能量判据**，它把正定性说成：任何非零向量带来的“能量” $\mathbf{x}^T S \mathbf{x}$ 都严格为正。

四条判据说的是同一件事，但验算的难度各不相同。用本章反复出现的矩阵

$$S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \quad (7.70)$$

逐条验证一遍。

第一条，特征值。第一节已经算出 $\lambda_1 = 1$ 、 $\lambda_2 = 3$ ，都为正，通过。

第二条，主元。做一次消元：第二行减去第一行的 $\frac{1}{2}$ 倍，

$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \longrightarrow \begin{bmatrix} 2 & 1 \\ 0 & \frac{3}{2} \end{bmatrix}. \quad (7.71)$$

两个主元 2 与 $\frac{3}{2}$ 都为正，通过。

第三条，顺序左上主子式。一阶主子式是左上角元素 $2 > 0$ ；二阶主子式是整个行列式 $2 \cdot 2 - 1 \cdot 1 = 3 > 0$ ，通过。

第四条，能量判据。设 $\mathbf{x} = (x_1, x_2)^\top$ ，逐步行列相乘：

$$\mathbf{x}^\top S \mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2x_1 + x_2 \\ x_1 + 2x_2 \end{bmatrix} = 2x_1^2 + 2x_1x_2 + 2x_2^2. \quad (7.72)$$

关键一步是配方：

$$2x_1^2 + 2x_1x_2 + 2x_2^2 = x_1^2 + x_2^2 + (x_1 + x_2)^2. \quad (7.73)$$

右边是三个平方之和，永远非负；要让它等于零，必须 $x_1 = 0$ 且 $x_2 = 0$ ，即 $\mathbf{x} = \mathbf{0}$ 。所以只要 $\mathbf{x} \neq \mathbf{0}$ ，就有 $\mathbf{x}^\top S \mathbf{x} > 0$ ，通过。

四条判据全部满足， S 是正定的。由于它们彼此等价，实际判别时任选最方便的一条即可。

对于一般的二维对称矩阵

$$S = \begin{bmatrix} a & b \\ b & c \end{bmatrix}, \quad (7.74)$$

第三条判据给出最常用的快速判别法：

$$\boxed{a > 0, \quad ac - b^2 > 0.} \quad (7.75)$$

这里第一个条件保证第一个主元为正，第二个条件就是行列式为正。也可以从主元看：消元后第二个主元是 $c - \frac{b^2}{a} = \frac{ac-b^2}{a}$ ，在 $a > 0$ 的前提下它为正当且仅当 $ac - b^2 > 0$ 。上面的例子中 $a = 2 > 0$ 、 $ac - b^2 = 3 > 0$ ，与逐条验证的结论一致。

正定矩阵与第 6 章的最小二乘自然联系起来。对任意矩阵 A （不必是方阵），

$$A^\top A \quad (7.76)$$

一定是对称的，因为 $(A^\top A)^\top = A^\top A$ 。再看它的能量：

$$\mathbf{x}^\top A^\top A \mathbf{x} = (A\mathbf{x})^\top (A\mathbf{x}) = \|A\mathbf{x}\|^2 \geq 0. \quad (7.77)$$

长度平方不可能为负，所以 $A^\top A$ 总是半正定——对称、且特征值都大于或等于零。什么时候能升级成正定？若 A 的列向量线性无关，则

$$A\mathbf{x} = \mathbf{0} \quad (7.78)$$

只有零解，于是对所有 $\mathbf{x} \neq \mathbf{0}$ 都有

$$\|A\mathbf{x}\|^2 > 0, \quad (7.79)$$

从而

$$\boxed{A^T A \text{ 正定.}} \quad (7.80)$$

这也解释了为什么满列秩时正规方程中的 $A^T A$ 一定可逆：正定矩阵特征值全为正，行列式等于它们的乘积，不可能为零。

半正定与正定只差在零上。半正定允许

$$\mathbf{x}^T S \mathbf{x} = 0 \quad (7.81)$$

在某些非零方向上出现，也就是特征值可以取零；正定排除了这些“平坦”方向，任何非零方向上的能量都严格为正。

由谱分解

$$S = Q \Lambda Q^T \quad (7.82)$$

可得

$$\mathbf{x}^T S \mathbf{x} = (Q^T \mathbf{x})^T \Lambda (Q^T \mathbf{x}). \quad (7.83)$$

若令

$$\mathbf{y} = Q^T \mathbf{x}, \quad (7.84)$$

即把 $\mathbf{x}$ 旋转到特征向量坐标系，则

$$\mathbf{x}^T S \mathbf{x} = \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2. \quad (7.85)$$

$\mathbf{x}^T S \mathbf{x}$ 这种每一项都是二次的表达式称为**二次型**。在特征向量坐标系下，二次型没有交叉项，只是各坐标平方的加权和，权重就是特征值。所以所有 $\lambda_i > 0$ 时，除 $\mathbf{x} = \mathbf{0}$ 外该二次型始终为正——这正是能量判据与特征值判据等价的原因。

几何上，方程

$$\mathbf{x}^T S \mathbf{x} = 1 \quad (7.86)$$

描述一个椭球，其主轴方向就是 S 的特征向量，主轴长度与 $1/\sqrt{\lambda_i}$ 成正比。用我们的例子，方程

$$2x_1^2 + 2x_1x_2 + 2x_2^2 = 1 \quad (7.87)$$

是一个椭圆：沿 $(1, -1)$ 方向的半轴长为 $1/\sqrt{\lambda_1} = 1$ ，沿 $(1, 1)$ 方向的半轴长为 $1/\sqrt{\lambda_2} = 1/\sqrt{3}$ 。特征值越大，对应方向被压得越短。

对称正定矩阵还可以从消元得到

$$S = LDL^T, \quad (7.88)$$

其中 D 的对角元素就是正主元；也可以从特征分解得到

$$S = Q \Lambda Q^T, \quad (7.89)$$

其中 Λ 的对角元素就是正特征值。这两个分解分别从消元和特征方向刻画了同一个正定结构。