

机器学习基础

2026 年 8 月 13 日

在正式开始前，向大家介绍一本很好的学习教材——邱锡鹏老师所著的《[神经网络与深度学习](#)》。本文主要基于该教材摘抄或改编，并附上笔者自己的理解，如有错误或问题，欢迎指正与交流！

1 概念

早在中学，我们就学过自变量和因变量。简单地说，由研究者主动操控的变量是自变量，随自变量变化而变化的量是因变量。因变量如何被自变量决定，取决于两者之间的映射关系：一次函数 $y = kx + b$ 、二次函数 $y = ax^2 + bx + c$ 、对数函数 $y = \ln x$ ，这些都是已知的、能写出具体表达式的映射关系。

但生活中变量之间的关系，往往没有现成的表达式。比如股市的走势如何变化，抛一次硬币哪面朝上，都没法用一个简单的函数写出来。于是人们想到近似的办法：做大量重复的实验，把结果一次次记录下来，再从中归纳规律。以抛硬币为例，前一百次里正面可能出现六七十次；抛到一万次，正面大约是五千多次；抛到十万次，正面所占的比例就越来越接近 50%。

值得思考的是：不管抛不抛、抛多少次，正面的占比似乎都趋向某个客观存在的值。它不会因为实验次数的多少而改变，只是随着采样增多，记录下来的频率越来越逼近它。当然，真去抛一百万次、一亿次硬币，成本是惊人的；好在计算机最擅长的就是这种海量重复计算，一秒钟就能“抛”上几千万次。机器学习正是利用了这一点：让计算机进行大规模的“采样”与计算，训练出一个模型，使它能够根据输入预测输出，并且尽可能猜得准。

顺着这个例子往下说。每一次实验记录下来的”输入—结果”对，就是一个样本，记作 $(\mathbf{x}, y)$ ： $\mathbf{x}$ 是输入特征， y 是标签，也就是我们想让模型预测的目标。

如果一件事只用一个数字就能描述，输入就是一个标量；但多数情况一个维度不够用。比如预测房价，要同时看面积、楼层、地段等好几个方面，把这些特征拼在一起，输入就成了一个 d 维向量：

$$\mathbf{x}^{(n)} = (x_1^{(n)}, x_2^{(n)}, \dots, x_d^{(n)})^T, \quad n = 1, 2, \dots, N,$$

其中上标 (n) 表示第 n 个样本， $x_t^{(n)}$ 是它第 t 维上的特征值。

N 个样本合在一起也就是我们的总数据集，我们一般会将其划分为训练集、验证集、测试集。其中，训练集用来学习模型参数，模型从它身上总结规律；验证集用来挑选超参数、判断何时停止训练；测试集只在最后评估一次模型的真实水平，模拟没见过的新数据，训练过程中绝不能碰。




图 1: 机器学习基本流程示意图

图 1 从下到上展示了机器学习的基本流程：学习算法 $\mathcal{A}$ 综合训练集 $\mathcal{D}$ 和预设的候选函数集合 $\mathcal{F}$ ，选出最能拟合数据规律的函数，记为 f^* 。

学出的模型 $f^*(\mathbf{x})$ 接收新样本的输入 $\mathbf{x}$ ，输出预测 $\hat{y}$ ；概率问题中也可以输出条件概率 $\hat{p}(y | \mathbf{x})$ 。机器学习的核心，就是从训练样本中学会输入到输出的规律，并推广到没见过数据。

2 学习准则、优化与评价

上一节给出了机器学习的整体流程。把问题落到实处还需要三个要素：用什么准则衡量模型好坏（学习准则）、如何求解最优参数（优化算法）、学

完以后如何评价（评价指标）。

2.1 损失函数

监督学习通常假设样本 $(\mathbf{x}, y)$ 是从一个未知但固定的分布 $p_r(\mathbf{x}, y)$ 中独立抽取的。我们真正关心的是模型在真实分布上的平均损失，即期望风险：

$$\mathcal{R}(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{x}, y) \sim p_r(\mathbf{x}, y)} [\mathcal{L}(y, f(\mathbf{x}; \boldsymbol{\theta}))],$$

其中 $\mathcal{L}(\cdot, \cdot)$ 为损失函数。 p_r 未知，期望风险算不出来，只能先选好损失函数，再用训练数据近似优化。

0-1 损失函数最直观的损失就是错误率：

$$\mathcal{L}(y, f(\mathbf{x}; \boldsymbol{\theta})) = \mathbb{I}(y \neq f(\mathbf{x}; \boldsymbol{\theta})),$$

其中 $\mathbb{I}(\cdot)$ 为指示函数：预测错误时取 1，否则取 0。它不连续、导数几乎处处为 0，没法用梯度方法优化，实践中常用连续可微的损失替代。

平方损失函数用于标签为实值的回归任务，一般不适用于分类：

$$\mathcal{L}(y, f(\mathbf{x}; \boldsymbol{\theta})) = \frac{1}{2}(y - f(\mathbf{x}; \boldsymbol{\theta}))^2.$$

交叉熵损失函数用于分类问题。设标签 $y \in \{1, \dots, C\}$ ，模型输出 $f(\mathbf{x}; \boldsymbol{\theta}) \in [0, 1]^C$ 为各类别的预测概率，总和为 1；标签写成 one-hot 向量 $\mathbf{y}$ （真实类别那一维为 1，其余为 0），它本身就是标签的真实分布。

两个分布 p 、 q 之间的交叉熵定义为

$$H(p, q) = - \sum_x p(x) \log q(x),$$

含义是：若按分布 q 设计最优编码，符号 x 的码长约为 $-\log q(x)$ ，越不可能的符号码长越长；而数据实际服从 p ，平均码长就要按 p 加权，即用 q 的编码去压缩 p 的数据所需的平均信息量。交叉熵是不对称的： $H(p, q)$ 的期望在 p 上取， $H(q, p)$ 在 q 上取，二者一般不相等。分类任务中必须把真实分布放在前面，因为我们关心的是“数据来自 p ，用 q 刻画它要付多大代价”；反过来没有对应的优化意义，而且 $p(x) = 0$ 的项在 $H(p, q)$ 中恒为 0、不影响损失，交换位置后则完全不同。

交叉熵可以分解为

$$H(p, q) = H(p) + D_{\text{KL}}(p \| q),$$

其中 $H(p) = -\sum_x p(x) \log p(x)$ 是 p 的熵，即按最优编码压缩 p 时不可再压缩的平均信息量；第二项

$$D_{\text{KL}}(p \| q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

是 KL 散度，表示真实分布是 p 却错用 q 编码时，相比最优编码白白多付出的平均信息量。它有两个关键性质。

一是非负：由不等式 $\log x \leq x - 1$,

$$\begin{aligned} -D_{\text{KL}}(p \| q) &= \sum_x p(x) \log \frac{q(x)}{p(x)} \leq \sum_x p(x) \left(\frac{q(x)}{p(x)} - 1 \right) \\ &= \sum_x q(x) - \sum_x p(x) = 0, \end{aligned}$$

等号仅当 p 、 q 几乎处处相同时成立。所以交叉熵永远不小于熵， $q = p$ 时取到下界。

二是不对称： $D_{\text{KL}}(p \| q) \neq D_{\text{KL}}(q \| p)$ 。对数按 p 加权—— p 概率大的地方， q 必须同样大，否则 $\log \frac{p(x)}{q(x)}$ 会爆炸；而 q 有、 p 没有的项根本不参与求和。因此 $D_{\text{KL}}(p \| q)$ 严厉惩罚“真实常见却预测罕见”，对“预测多余”视而不见，它不是严格意义上的距离。

熵 $H(p)$ 由数据本身决定，与参数无关，所以最小化交叉熵等价于最小化 KL 散度，即让预测分布尽量贴近真实分布。这就是分类问题用交叉熵损失的统计学解释。

代入 one-hot 标签，交叉熵损失简化为

$$\mathcal{L}(\mathbf{y}, f(\mathbf{x}; \boldsymbol{\theta})) = -\mathbf{y}^T \log f(\mathbf{x}; \boldsymbol{\theta}) = -\log f_{\mathbf{y}}(\mathbf{x}; \boldsymbol{\theta}),$$

即真实类别预测概率的负对数。由于 $f_{\mathbf{y}}(\mathbf{x}; \boldsymbol{\theta})$ 正是真实类别的似然，交叉熵损失也就是负对数似然，最小化它等价于极大似然估计。

Hinge 损失函数用于二分类。取 $y \in \{-1, +1\}$ ，模型输出实数 $f(\mathbf{x}; \boldsymbol{\theta})$ ，定义为

$$\mathcal{L}(y, f(\mathbf{x}; \boldsymbol{\theta})) = \max(0, 1 - yf(\mathbf{x}; \boldsymbol{\theta})) \triangleq [1 - yf(\mathbf{x}; \boldsymbol{\theta})]_+.$$

为什么这样设计? 预测正确的充要条件是 $yf(\mathbf{x}; \boldsymbol{\theta}) > 0$, 最理想的 0-1 损失不可导, Hinge 损失是它的分段线性凸上界, 并且更进一步: 要求 $yf(\mathbf{x}; \boldsymbol{\theta}) \geq 1$ 才零惩罚, 即不仅要分对, 还要留出至少为 1 的间隔。好处有二: 凸函数便于优化, 与支持向量机最大间隔的思想一致; 外层 $\max(0, \cdot)$ 让分得又对又远的样本不产生梯度, 只有间隔不足或分错的样本推动参数更新。

2.2 风险最小化准则

三种”风险”的关系是学习准则的核心。期望风险是真正的目标, 但算不出来; 手头只有训练集, 于是用训练集上的平均损失来近似, 即经验风险:

$$\mathcal{R}^{\text{emp}}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \boldsymbol{\theta})).$$

由大数定律, $N \rightarrow \infty$ 时经验风险收敛到期望风险; 但样本总是有限的, 经验风险小不代表期望风险小, 两者之差就是泛化误差。经验风险最小化准则

$$\boldsymbol{\theta}^* = \arg \min_{\boldsymbol{\theta}} \mathcal{R}^{\text{emp}}(\boldsymbol{\theta})$$

只盯训练误差, 模型太复杂时会把噪声也当成规律学进去, 导致过拟合; 反过来, 模型能力不足、连训练数据都拟合不好, 就是欠拟合。图 2 给出了这三种情形的直观对比。




图 2: 欠拟合、正常与过拟合的直观对比

结构风险最小化在经验风险后面加一个复杂度惩罚项:

$$\boldsymbol{\theta}^* = \arg \min_{\boldsymbol{\theta}} \mathcal{R}^{\text{emp}}(\boldsymbol{\theta}) + \lambda \Omega(\boldsymbol{\theta}),$$

其中 $\Omega(\boldsymbol{\theta})$ 衡量模型复杂度, $\lambda \geq 0$ 为权衡系数。理论上期望风险大致可被“经验风险加复杂度项”上界约束, 所以结构风险相当于在最小化这个上界, 比经验风险更接近真正的目标。最常用 ℓ_2 正则化; ℓ_1 会带来稀疏解。从贝叶斯角度看, 正则化就是给参数加先验。

一句话总结: 期望风险是目标, 经验风险是有限样本下的近似, 结构风险是在近似之上再加一道复杂度的保险。 λ 这类超参数靠验证集挑选; 数据少时用 K 折交叉验证: 把数据均分 K 份, 轮流用一份验证、其余训练, 取 K 次结果的平均。

2.3 优化算法

先分清两个概念: 模型参数 $\boldsymbol{\theta}$ 由优化算法直接学习; 学习率、正则化系数、网络层数这类定义模型结构或优化策略的量叫超参数, 训练中学不到, 通常靠人工经验、网格搜索、随机搜索等方法结合验证集来选。

最常用的优化算法是梯度下降: 梯度指向增长最快的方向, 沿负梯度走下降最快。第 t 次迭代的更新公式为

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \alpha \frac{\partial \mathcal{R}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}_t} = \boldsymbol{\theta}_t - \alpha \cdot \frac{1}{N} \sum_{n=1}^N \frac{\partial \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \boldsymbol{\theta}))}{\partial \boldsymbol{\theta}},$$

其中 α 为学习率。

按每次迭代用多少样本, 梯度下降分三种。记单个样本的梯度为

$$\mathbf{g}^{(n)}(\boldsymbol{\theta}) = \frac{\partial \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \boldsymbol{\theta}))}{\partial \boldsymbol{\theta}},$$

三者的区别在于更新用的梯度怎么算:

批量梯度下降用全体样本的平均梯度,

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \alpha \cdot \frac{1}{N} \sum_{n=1}^N \mathbf{g}^{(n)}(\boldsymbol{\theta}_t),$$

每步方向准确, 但数据量大时算一次就要扫完整个训练集, 开销太高。

随机梯度下降每次随机取一个样本, 直接用它的梯度更新:

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \alpha \mathbf{g}^{(n)}(\boldsymbol{\theta}_t).$$




图 3: 提前停止示意图

单步极其便宜。它之所以可行，是因为单样本梯度是平均梯度的无偏估计：样本随机抽取时 $\mathbb{E}_n[\mathbf{g}^{(n)}] = \frac{1}{N} \sum_{n=1}^N \mathbf{g}^{(n)}$ ，期望方向和全样本梯度一致，长期来看更新方向是对的；而且单样本带来的噪声反而有助于跳出非凸问题中较差的局部区域。缺点是它无法并行：每次只处理一个样本， N 次更新只能一个接一个串行进行，没法把样本组织成矩阵做批量运算，白白浪费 GPU 的并行能力。

小批量梯度下降每次随机取 K 个样本组成子集 $\mathcal{S}_t$ ，用它们的平均梯度更新：

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \alpha \cdot \frac{1}{K} \sum_{(\mathbf{x}^{(n)}, y^{(n)}) \in \mathcal{S}_t} \mathbf{g}^{(n)}(\boldsymbol{\theta}_t),$$

K 实践中常取 2 的幂。它是前两种的折中：平均 K 个样本后梯度噪声比随机梯度小，同时一个批次的计算可以组织成矩阵运算并行完成，兼顾效率与稳定，是深度学习的主流做法。

另外还可以用提前停止缓解过拟合（图 3）：训练误差持续下降、验证误差却开始回升时，就终止训练。

2.4 评价指标

分类问题最常用的指标是准确率和错误率：

$$\mathcal{A} = \frac{1}{N'} \sum_{n=1}^{N'} \mathbb{I}(y^{(n)} = \hat{y}^{(n)}), \quad \mathcal{E} = 1 - \mathcal{A}.$$

准确率是所有类别的整体平均。要看单个类别的表现，对类别 c 把预测结果分四种：真正例 TP_c （真实为 c 、预测为 c ）、假负例 FN_c （真实为 c 、

预测非 c)、假正例 FP_c (真实非 c 、预测为 c)、真负例 TN_c 。这四种情况可以整理成类别 c 的混淆矩阵, 如图 4 所示。

		预测类别	
		$\hat{y} = c$	$\hat{y} \neq c$
真实类别	$y = c$	TP_c	FN_c
	$y \neq c$	FP_c	TN_c

图 4: 类别 c 的混淆矩阵

精确率是” 预测为 c 的样本中有多少是真的”, 召回率是” 真实为 c 的样本中找回了多少”:

$$\mathcal{P}_c = \frac{TP_c}{TP_c + FP_c}, \quad \mathcal{R}_c = \frac{TP_c}{TP_c + FN_c}.$$

两者往往此消彼长, 常用调和平均 F 值综合:

$$\mathcal{F}_c = \frac{(1 + \beta^2) \times \mathcal{P}_c \times \mathcal{R}_c}{\beta^2 \times \mathcal{P}_c + \mathcal{R}_c},$$

$\beta = 1$ 时即 F1 值。

汇总所有类别有两种平均方式: 宏平均先算每类指标再取平均, 大小类别话语权相同; 微平均先汇总各类的 TP、FP、FN 再算, 容易被大类别主导。类别不均衡时, 宏平均更能反映小类性能。此外还可以调整分类阈值画 ROC、PR 曲线, 用 AUC 做更全面的评价。最后一个容易忽视的维度是概率校准: 模型经常给出 0.9 的预测概率, 那这些预测里就该有九成左右是对的, 否则概率输出不可信。

3 偏差-方差分解

模型太简单会欠拟合, 太复杂会过拟合, 偏差-方差分解把这件事定量地拆开来看。以回归问题、平方损失为例 (结论同样适用于分类)。模型的期望风险为

$$\mathcal{R}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim p_r(\mathbf{x}, y)} [(y - f(\mathbf{x}))^2].$$

给定 $\mathbf{x}$ ，真实分布下的 y 是随机变量，围绕一个理论均值波动，这个理论均值记为

$$f^*(\mathbf{x}) = \mathbb{E}_{y \sim p_r(y|\mathbf{x})}[y],$$

它代表数据背后的真实规律； y 对 $f^*(\mathbf{x})$ 的偏离就是噪声，随机噪声的数据分布均值为 0。

在 f^* 处把期望错误拆开。约定 $\mathbb{E}_{\mathbf{x},y}$ 对 $(\mathbf{x}, y) \sim p_r(\mathbf{x}, y)$ 取期望， $\mathbb{E}_{y|\mathbf{x}}$ 固定 $\mathbf{x}$ 、只对 y 取期望：

$$\begin{aligned}\mathcal{R}(f) &= \mathbb{E}_{\mathbf{x},y} \left[(y - f^*(\mathbf{x}) + f^*(\mathbf{x}) - f(\mathbf{x}))^2 \right] \\ &= \mathbb{E}_{\mathbf{x},y} \left[(y - f^*(\mathbf{x}))^2 \right] + \mathbb{E}_{\mathbf{x}} \left[(f(\mathbf{x}) - f^*(\mathbf{x}))^2 \right] \\ &\quad + 2 \mathbb{E}_{\mathbf{x},y} \left[(y - f^*(\mathbf{x})) (f^*(\mathbf{x}) - f(\mathbf{x})) \right].\end{aligned}$$

交叉项为 0，用全期望公式把期望拆成“先固定 $\mathbf{x}$ 对 y 取、再对 $\mathbf{x}$ 取”即可看出：

$$\begin{aligned}\mathbb{E}_{\mathbf{x},y} \left[(y - f^*(\mathbf{x})) (f^*(\mathbf{x}) - f(\mathbf{x})) \right] &= \mathbb{E}_{\mathbf{x}} \left[\mathbb{E}_{y|\mathbf{x}} \left[(y - f^*(\mathbf{x})) (f^*(\mathbf{x}) - f(\mathbf{x})) \right] \right] \\ &= \mathbb{E}_{\mathbf{x}} \left[(f^*(\mathbf{x}) - f(\mathbf{x})) \mathbb{E}_{y|\mathbf{x}} [y - f^*(\mathbf{x})] \right] = 0.\end{aligned}$$

固定 $\mathbf{x}$ 后 $f^*(\mathbf{x}) - f(\mathbf{x})$ 是常数，可提出 $\mathbb{E}_{y|\mathbf{x}}$ ；而 $\mathbb{E}_{y|\mathbf{x}}[y - f^*(\mathbf{x})] = 0$ ——给定 $\mathbf{x}$ 时真实值 y 都围绕 $f^*(\mathbf{x})$ 波动，即噪声均值为 0。于是

$$\mathcal{R}(f) = \mathbb{E}_{\mathbf{x}} \left[(f(\mathbf{x}) - f^*(\mathbf{x}))^2 \right] + \varepsilon, \quad \varepsilon = \mathbb{E}_{\mathbf{x},y} \left[(y - f^*(\mathbf{x}))^2 \right].$$

ε 是噪声的期望大小，与 f 无关，理论最优模型也避免不了；第一项是 f 与 f^* 的差距，才是能优化的部分。故 $\mathcal{R}(f)$ 在 $f = f^*$ 处取最小， f^* 即平方损失下的理论最优模型。

但 $f(\mathbf{x})$ 在具体训练集 $\mathcal{D}$ 上学出，换批数据就换个模型。评价算法本身，要对训练集取平均。记 $f_{\mathcal{D}}$ 为 $\mathcal{D}$ 上学到的模型，对单个 $\mathbf{x}$ 插入中间项 $\mathbb{E}_{\mathcal{D}}[f_{\mathcal{D}}(\mathbf{x})]$ 再展开：

$$\begin{aligned}\mathbb{E}_{\mathcal{D}} \left[(f_{\mathcal{D}}(\mathbf{x}) - f^*(\mathbf{x}))^2 \right] &= \mathbb{E}_{\mathcal{D}} \left[(f_{\mathcal{D}}(\mathbf{x}) - \mathbb{E}_{\mathcal{D}}[f_{\mathcal{D}}(\mathbf{x})] + \mathbb{E}_{\mathcal{D}}[f_{\mathcal{D}}(\mathbf{x})] - f^*(\mathbf{x}))^2 \right] \\ &= \underbrace{\left(\mathbb{E}_{\mathcal{D}}[f_{\mathcal{D}}(\mathbf{x})] - f^*(\mathbf{x}) \right)^2}_{\text{偏差}^2} + \underbrace{\mathbb{E}_{\mathcal{D}} \left[(f_{\mathcal{D}}(\mathbf{x}) - \mathbb{E}_{\mathcal{D}}[f_{\mathcal{D}}(\mathbf{x})])^2 \right]}_{\text{方差}},\end{aligned}$$


这里的交叉项同样为 0：记平均模型 $\bar{f}(\mathbf{x}) = \mathbb{E}_{\mathcal{D}}[f_{\mathcal{D}}(\mathbf{x})]$ ，固定 $\mathbf{x}$ 时 $\bar{f}(\mathbf{x})$ 、 $f^*(\mathbf{x})$ 都与 $\mathcal{D}$ 无关，是常数，第二个因子可提出期望：

$$\begin{aligned} \mathbb{E}_{\mathcal{D}} \left[(f_{\mathcal{D}}(\mathbf{x}) - \bar{f}(\mathbf{x})) (\bar{f}(\mathbf{x}) - f^*(\mathbf{x})) \right] \\ = (\bar{f}(\mathbf{x}) - f^*(\mathbf{x})) \mathbb{E}_{\mathcal{D}} [f_{\mathcal{D}}(\mathbf{x}) - \bar{f}(\mathbf{x})] = 0, \end{aligned}$$

因为 $\mathbb{E}_{\mathcal{D}}[f_{\mathcal{D}}(\mathbf{x}) - \bar{f}(\mathbf{x})] = \bar{f}(\mathbf{x}) - \bar{f}(\mathbf{x}) = 0$ 。代回上式，得最终分解：

$$\mathcal{R}(f) = \text{偏差}^2 + \text{方差} + \varepsilon.$$

图 5 用打靶比喻四种组合：靶心是最优模型 $f^*(\mathbf{x})$ ，蓝点是不同训练集上学到的 $f_{\mathcal{D}}(\mathbf{x})$ ；点群中心离靶心的距离是偏差，点群散开的程度是方差。



偏差是平均模型与最优模型的差距，衡量拟合能力；方差是模型随训练集变动的程度，衡量对数据扰动的敏感度。两者此消彼长：复杂度升高，偏差减小、方差增大，于是过拟合。调大正则化系数 λ 可以压方差，但偏差上升， λ 过大时期望错误反而回升；方差还会随样本增多而减小，数据够多就可以放心用更强的模型降偏差。注意最优复杂度并不一定落在偏差曲线与方差曲线的交点。




图 6: 期望错误、偏差与方差随模型复杂度的变化